

Yapılandırılmamış Metinlerden Otomatik Bilgi Grafiği Çıkarımı: Güncel Yöntemler, Yaklaşımlar ve Kıyaslama Analizleri (2024–2026)

Bilgi Grafiği Mühendisliğinde Paradigma Değişimi

Geleneksel bilgi grafiği (KG) inşası; ontoloji mühendisliği, bilgi çıkarımı (ner/ilişki çıkarımı) ve bilgi füzyonundan oluşan üç katmanlı ardışık bir mimariye dayanmaktaydı¹. Büyük Dil Modellerinin (LLM) ortaya çıkışından önce bu süreçler kural tabanlı, istatistiksel ve sembolik yaklaşımlarla yürütülmekteydi¹. Ancak bu geleneksel mimari, üç temel kronik sorunla karşı karşıyaydı: kural ve denetimli modellerin yeni alanlara genelleymemesinden kaynaklanan ölçeklenebilirlik ve veri seyrekleşmesi (data sparsity); insan uzmanlığına olan aşırı bağımlılık ve esneklik yoksunluğu; ve erken aşamadaki hataların sonraki adımlara katlanarak aktarıldığı ardışık hata birikimi (error cascading)¹.

2024–2026 dönemi, bu statik ve kural odaklı yaklaşımlardan; bilgi edinimi, organizasyon ve akıl yürütmenin üretici ve kendi kendini geliştiren bir ekosistem içinde iç içe geçtiği "LLM destekli, birleşik ve uyarlanabilir çerçevelere" doğru radikal bir paradigma değişimine sahne olmaktadır¹. Temsili öğrenmenin gelişmesi ve ardından LLM'lerin parametrik belleklerinde saklı örtük bilgilerin keşfedilmesi, ontolojilerin sıfırdan oluşturulması veya metinlerden doğrudan çıkarılması süreçlerini kökten değiştirmiştir¹.

Bu dönüşümün arkasındaki en büyük pratik motivasyonlardan biri, geleneksel vektör tabanlı RAG (Retrieval-Augmented Generation) sistemlerinin yapısal sınırlarıdır⁴. Vektör benzerliği odaklı bilgi geri kazanımı pratik veri sorgulamalarında başarılı olsa da metin parçalanması (chunk fragmentation), semantik çöküş (semantic collapse), zamansal körlük (temporal blindness) ve benzersiz tanımlayıcı (identifier) hataları gibi yapısal engellere takılmaktadır⁴. Örneğin, karmaşık bir ürün yapısındaki parça ilişkileri veya regülasyonlar arasındaki çapraz geçişler, basit bir semantik benzerlik aramasıyla geri kazanılamaz⁵. Graf tabanlı yaklaşımlar (GraphRAG), bilgiyi tipize edilmiş düğümler (varlıklar, olaylar) ve kenarlar (ilişkiler) halinde yapılandırarak bu tikanıklığı aşmaktadır⁴. Bu yapı sayesinde, sistemler çok adımlı ilişkisel sorguları (multi-hop reasoning) izleyebilir, net bir akıl yürütme izi (reasoning trace) sunabilir ve doğrulanabilir, şeffaf kaynak bağlantılarıyla yanıtlar üretebilir⁴.

Uçtan Uca Sinirsel Yöntemler ve Varlık-İlişki Çıkarımı

Otomatik bilgi grafiği inşasında, devasa kapalı kaynaklı modellerin yüksek token maliyetlerini ve gecikme sürelerini aşmak için özel olarak tasarlanmış küçük, hızlı ve uçtan uca sinirsel modeller

ön plana çıkmaktadır⁴. Bu yaklaşımlar temelde çift yönlü kodlayıcı (bidirectional encoder) tabanlı eşleştiriciler ve optimize edilmiş küçük üretici kod çözücü (decoder-only) modelleri olarak ikiye ayrılmaktadır.

Sıfır örnekli (zero-shot) varlık tanıma görevlerinde öncü olan GLiNER çerçevesi, geleneksel Named Entity Recognition (NER) görevini üretici bir süreç yerine, birleşik bir çift yönlü kodlayıcı içinde metin dilimleri (spans) ile varlık tipi tanımları arasındaki semantik benzerlik eşleştirmesine dönüştürerek maliyet ve hız avantajı sağlamıştır⁹. Bu paradigmanın en güncel sürümü olan GLiNER2; hiyerarşik yapılandırma desteği, iç içe geçmiş (nested) varlık sınırlarının tespiti ve şema güdümlü arayüzler üzerinden çoklu görev (NER, ilişki çıkarımı ve metin sınıflandırma) yönetimi sunarak otonom sistemlere pratik bir altyapı sağlamaktadır¹¹. Benzer şekilde, GLiREL ve GLiDRE gibi uzantılar bu kodlayıcı tabanlı yapıyı belge düzeyinde sıfır örnekli ilişki çıkarımına taşımıştır⁹. Bir diğer önemli uçtan uca yaklaşım olan ReLiK, bilgi çıkarımını (cIE: NER + RE + EL) hızlı bir "Retriever-Reader" (Geri Kazanıncı-Okuyucu) mimarisiyle kurgulamaktadır¹⁴. ReLiK, girdi metnine dayalı olarak, harici bir indeks içinden çıkarılabilecek olası varlık ve ilişki tanımlarını çift yönlü kodlayıcı (Retriever) ile çekmekte; ardından ortak bir Okuyucu (Reader) katmanı ile metindeki doğru dilimleri bu tanımlarla tek bir ileri besleme (forward pass) adımıyla ilişkilendirmektedir¹⁴. Bu yaklaşım, rakip üretici sistemlere kıyasla akademik bütçelerle eğitilebilmekte ve 40 kata varan çıkarım hızı avantajı sunmaktadır¹⁴.

Küçük üretici modeller tarafında ise SciPhi tarafından sunulan Triplex modeli, Phi-3-3.8B mimarisi üzerinde DPO (Direct Preference Optimization) ve KTO (Knowledge Triplet Optimization) yöntemleriyle eğitilmiş özel bir dil modelidir¹⁷. Triplex, yapılandırılmamış metinlerden doğrudan konu-yüklem-nesne (SPO) formatında semantik üçlüler (triplets) çıkarabilmekte ve GPT-4o düzeyinde bir doğruluğu, onun 60'ta biri kadar bir maliyetle sunarak yerel ve özel KG inşasını pratik hale getirmektedir¹⁷. Ayrıca LightKGG, küçük ölçekli dil modellerini (SLM) yapılandırılmış NLP görevlerinde optimize ederek yüksek verimlilik sağlarken; InvertiTune çerçevesi ise tek atışlık (single-shot) metinden grafiğe dönüşüm için yüksek kaliteli veri sentezi gerçekleştirmektedir²⁰.

Tüm bu modellere rağmen, karmaşık profesyonel metinlerde (örneğin nadir hastalık tanı raporlarının yer aldığı RareDis veri kümesinde) uçtan uca ilişki çıkarımı (E2ERE) hâlâ önemli bir zorluktur²¹. Kesintili (discontinuous) ve iç içe geçmiş varlık sınırları, NER aşamasında yüksek hata oranlarına yol açmaktadır²². Yapılan güncel çalışmalar, tıp gibi derin uzmanlık gerektiren alanlarda bile genel yetenekli büyük modellerin küçük ölçekli talimat ayarlı (instruction-tuned) alan modelleriyle yarıştığını, ancak sıfır örnekli RTE görevlerinde F1 skorlarının hâlâ 0.5 barajını aşmakta zorlandığını göstermektedir²³.

Ontoloji Öğrenimi ve Dinamik Şema Türetimi

Ontoloji öğrenimi süreci, geleneksel olarak "Ontoloji Öğrenme Katman Pastası" (Ontology Learning Layer Cake) modeliyle açıklanmaktadır²⁵. Bu hiyerarşik yapı; terimlerin ve eşanlamlıların çıkarılmasıyla başlar, kavramların oluşturulması, taksonomik ilişkilerin (is-a) kurulması, taksonomik olmayan genel ilişkilerin saptanması ve nihayetinde aksiyom şemalarının oluşturulmasıyla zirveye ulaşır²⁵.

Geleneksel yöntemler bu katmanları Stanford Dependency Parser, HITS algoritması veya PLSA gibi dilbilimsel ve istatistiksel araçlarla parça parça inşa ederken²⁵; 2024–2026 dönemi yaklaşımları, önceden tanımlanmış katı ontolojilere olan bağımlılığı ortadan kaldırarak metinden dinamik olarak şema türeten (unsupervised schema induction) sistemlere odaklanmaktadır²⁹. Bu alandaki en kapsamlı çalışmalardan biri olan AutoSchemaKG, otonom şema türetimini kavramlaştırma (conceptualization) süreci üzerinden yürütür²⁹. Sistem, metinden sadece geleneksel varlık ilişkilerini değil, aynı zamanda zaman ve nedensellik boyutunu yakalamak için olayları (events) da birinci sınıf vatandaş olarak ayıklar²⁹. Varlıklar hiyerarşik kavram gruplarına soyutlanırken, komşu düğümlerin kimlik ve ilişki bilgileri bağlamsal girdi olarak modele sunulur ve böylece üretilen şemanın graf yapısıyla sıkı sıkıya uyumlu olması sağlanır²⁹. Bu otonom şema indüksiyonu yöntemiyle 50 milyondan fazla belgeden (Dolma veri kümesi, Wikipedia, Common Crawl) hareketle oluşturulan devasa ATLAS bilgi grafiği ailesi (ATLAS-Wiki, ATLAS-Pes2o, ATLAS-CC), milyarlarca kenarı otonom olarak birbirine bağlamaktadır³¹. Bir diğer paradigma olan TRACE-KG, karmaşık ve çok modlu (multimodal) belgelerden (metin, tablo, diyagram, denklem) veri odaklı bir hiyerarşik şema türeten "TRACE-Schema" mekanizmasını kullanmaktadır³⁵. TRACE-KG, varlık ve ilişkileri HDBSCAN algoritması kullanarak semantik benzerlik komşuluklarında kümelemekte ve ardından LLM tabanlı yapılandırılmış operasyonlarla (MergeEntities, ModifyEntity vb.) birleştirmektedir³⁶. Koşullu ve zamana bağlı ilişkileri kenarlar üzerindeki yapılandırılmış nitelik belirteçleri (qualifiers) ile çözen sistem, üretilen tüm graf elemanlarını orijinal metindeki sayfa ve bölge koordinatlarına (provenance) bağlayarak tam izlenebilirlik sunmaktadır³⁵.

Daha dar ve uzmanlık gerektiren alanlarda ise şu özel çerçeveler öne çıkmaktadır:

- **OntoEKG (2026):** Finans, lojistik ve veri yönetimi gibi kurumsal sektörlerin karmaşık belgelerinden sektöre özgü ontolojilerin otonom üretimi için tasarlanmış bir akıştır³⁸.
- **Evontree:** Düşük kaynaklı alanlarda, dışarıdan büyük veri beslemesi yapmak yerine, modelin pre-training aşamasında edindiği örtük bilgileri basit ontoloji kurallarıyla uyandıran bir çerçevedir³. Modelin bir ilişki üçlüsüne yönelik doğrulama inancını ölçmek için yeni nesil token tahmin karmaşıklığını (next-token prediction perplexity) temel alan ConfirmValue metriğini kullanmakta ve LoRA ile kendi kendini eğitmesini sağlamaktadır³.
- **GenOM:** Ontoloji kavramlarının semantik temsillerini metinsel tanımlar üreterek zenginleştiren ve hassas ontoloji hizalaması (ontology alignment) gerçekleştiren bir sistemdir³⁹.
- **TICO (Time Constrained Instance-guided Ontology Evolution):** RDF veri akışlarındaki değişimleri 4-D Fluents yaklaşımıyla zamansal dilimlere (Time Slices) ayırarak ontolojinin zaman içinde otonom evrimleşmesini (ontology evolution) yöneten bir araçtır⁴⁰.

Ayrıca, tek aşamalı LLM üretimlerinin neden olduğu yapısal tekrarları ve zayıf ontolojik tasarımı engellemek amacıyla LangGraph tabanlı çoklu ajan (multi-agent) mimarileri yaygınlaşmaktadır⁴¹. 2026 tarihli "Towards Automated Ontology Generation" çalışmasında önerildiği üzere süreç; Alan Uzmanı, Yönetici (Manager), Kodlayıcı (Coder) ve Kalite Güvence (QA) rollerine bölünmektedir⁴¹. Yönetici ajan, MODL veya sınıf yeniden kullanımı gibi hazır Ontoloji Tasarım Kalıplarını (ODP) planlamakta; Kodlayıcı ajan şemayı OWL formatında yazmakta; ardından

entegre bir döngüde SPARQL sorgu doğrulama ajanları in-memory graf üzerinde sözdizimsel ve mantıksal denetimler yaparak hataları kendi kendine düzeltmektedir⁴¹. Ontogenia ise ontoloji üretiminde meta-bilişsel yönlendirme (Metacognitive Prompting) kullanarak modelin kendi kendini yansıtmasını (self-reflection) ve yapısal hataları sentez sırasında düzeltmesini sağlamaktadır¹.

Gelişmiş Bilgi Grafiği Doğruluk ve Başarım Benchleri

Bilgi grafiklerinin inşası, tamamlanması ve olgusal doğruluğunun değerlendirilmesi amacıyla 2024–2026 döneminde yeni nesil kıyaslama (benchmark) platformları geliştirilmiştir.

MINE (Measure of Information in Nodes and Edges)

Orijinal olarak KGGen çerçevesi ile sunulan MINE, yapılandırılmamış metinlerden üretilen otomatik bilgi grafiklerinin olgusal geri kazanılabilirlik (factual recoverability) ve bağlamsal koruma düzeyini ölçen temel bir kıyası oluşturmaktadır²⁰. MINE, doğrudan ham metinden çıkarılan kontrol grubu üçlülere ile otonom üretilen grafik yapılarını karşılaştırarak, çıkarılan bilginin ne kadarının grafa kayıpsız aktarıldığını doğrular⁴⁵.

FactCheck (EDBT 2026)

Shami ve diğerleri tarafından sunulan FactCheck, otomatik olarak inşa edilen bilgi grafiklerindeki SPO üçlülerinin gerçek dünya doğruluğunu test etmek için tasarlanmış geniş kapsamlı bir kıyaslama aracıdır⁴⁷. FactCheck, LLM'lerin olgusal doğrulamalarını üç ana ekseninde değerlendirir: modelin parametrik iç bilgisi (internal knowledge); RAG entegrasyonu ile harici Google Arama SERP sonuçları içeren 2 milyondan fazla belgelik dış kanıt havuzu; ve çoklu model konsensüs (consensus-based majority voting) stratejileri⁴⁷. FactCheck deneyleri, LLM'lerin doğrudan olgu doğrulayıcı olarak konumlandırılmasının halüsinasyon riskleri nedeniyle kararsız olduğunu ve RAG entegrasyonunun yüksek hesaplama maliyetine rağmen dalgalı bir performans sergilediğini ortaya koymuştur⁴⁸.

KGI-Bench

KG entegrasyonu (Knowledge Graph Integration) iş akışlarını bütünsel olarak test eden bu yeni kıyaslama sistemi; sisteme beslenen çok formatlı verilerin mevcut graf yapısına eklenmesi süreçlerini Kapsam (coverage), Doğruluk (correctness) ve Tutarlılık (consistency) olmak üzere üç temel metrik üzerinden, film etki alanı gibi referans veri kümesi gruplarıyla test eder⁵⁰.

KBG (Knowledge Benchmark Graph)

Makine öğrenmesi modellerinin (özellikle Grafik Sinir Ağları - GNN) performans kayıtlarını ve veri kümesi ilişkilerini yapılandırılmış performance(data, model) olguları şeklinde saklayan devasa bir benchmark grafıdır⁵¹. KBG, yeni ve hiç görülmemiş veri kümeleri için en uygun GNN mimarilerini otomatik seçmek (AutoML) amacıyla semantik benzerlik algoritmalarını ve LLM'leri entegre etmektedir⁵¹.

Aşağıdaki Tablo 1'de, bu kıyaslama araçlarının odak noktaları, değerlendirdikleri temel metrikler

ve mimari kapsamları karşılaştırmalı olarak sunulmaktadır.

Tablo 1: Bilgi Grafiği Doğruluk, Entegrasyon ve Doğrulama Kıyaslama Platformları (2024–2026)

Kıyaslama Platformu (Benchmark)	Temel Amacı ve Odak Noktası	Değerlendirilen Ana Metrikler	Referans Veri Kümeleri ve Kaynaklar	Mimari Kapsamı ve Yaklaşımı
MINE [cite: 45, 52, 53]	Otomatik çıkarılan grafların olgusal tutarlılığını ve bilgi kaybını ölçmek.	Bilgi Koruma Oranı (BS-R/C), Bağlantı Yoğunluğu, Düğüm/Kenar Dağılımı.	Metin-üçlü eşleştirmeli makaleler, KGGen referansları.	Bilgi çıkarım hatlarının olgu geri kazanım verimliliğini test eden içsel analiz.
FactCheck [cite: 47, 48, 54]	KG üçlülerinin gerçek dünya olgularıyla doğruluğunu denetlemek.	İç Bilgi Doğruluğu, RAG Kanıt Uyumu, Konsensüs Başarımı.	DBpedia, YAGO, FactBench (2M+ RAG belgesi).	LLM iç belleği, Google SERP simülasyonu ve çoklu model oylama entegrasyonu.
KGI-Bench [cite: 50]	KG veri entegrasyonu (pipeline) kalitesini uçtan uca test etmek.	Kapsam (Coverage), Doğruluk (Correctness), Tutarlılık (Consistency).	Film etki alanı (Movie seed KG, overlapping input data).	Mevcut bir grafa farklı formatlarda yeni veri ekleyen entegrasyon hatlarının testi.
KBG (Knowledge Benchmark Graph) [cite: 51]	GNN model tasarımı ve veri kümesi uyumluluğunu optimize etmek.	Dataset Benzerliği, Model Performansı, Tahmin Doğruluğu.	26.206 GNN modeli, 2M+ yapılandırılmış olgu kaydı.	AutoML sistemleri için veri-model eşleşmelerini semantik graflar üzerinden sorgulama.

Uç bilgi çıkarım graflarının nihai performansı ise, çok adımlı akıl yürütme (multi-hop QA) yeteneği gerektiren MuSiQue, 2WikiMultihopQA ve HotpotQA gibi dışsal (downstream) veri kümeleri üzerinde test edilmektedir⁵⁵. Tablo 2, geleneksel bilgi edinme yöntemleri ile güncel graf tabanlı RAG mimarilerinin bu zorlu çok adımlı görevlerdeki başarımlarını göstermektedir.

Tablo 2: Çok Adımlı Soru Cevaplama Başarımlarını Karşılaştırması (Exact Match ve F1 Skorları)

Geri Kazanım ve RAG Algoritması	MuSiQue EM (%)	MuSiQue F1 (%)	2Wiki EM (%)	2Wiki F1 (%)	HotpotQA EM (%)	HotpotQA F1 (%)
Geri Kazanım sız (No Retriever) [cite: 55, 56]	17,6	26,1	36,5	42,8	37,0	47,3
Contriever (Yoğun Vektör) [cite: 55, 56]	24,0	31,3	38,1	41,9	51,3	62,3
BM25 (Seyrek Sözcük) [cite: 55, 56]	20,3	28,8	47,9	51,2	52,0	63,4
LightRAG (Hafif Graf) [cite: 55]	20,0	29,3	38,6	44,6	33,3	44,9
MiniRAG	9,6	16,8	13,2	21,4	47,1	59,9

(SLM Tabanlı Graf) [cite: 55]						
Microsoft GraphRAG [cite: 8, 55]	27,3	38,5	51,4	58,6	55,2	68,6
AutoSchemaKG + HippoRAG Uzantısı [cite: 31, 55]	23,6	36,5	54,8	63,2	—	—

Alana Özgü Entegrasyonlar ve Alan Bağımsız Genelleme

Otomatik bilgi grafiği inşasında karşılaşılan en büyük yapısal ayrım, "herhangi bir alana sıfırdan uyarlanabilen genel amaçlı yapılar" ile "derin semantik kurallarla donatılmış alana özgü entegrasyonlar" arasındadır.

Genel Amaçlı ve Alan Bağımsız Çerçeveler

AutoSchemaKG, Triplex ve ODKE+ gibi modern açık alan bilgi çıkarma sistemleri, önceden tanımlanmış şemalara bağımlı kalmaksızın web ölçeğindeki devasa veri havuzlarından otonom şemalar türetebilmektedir²⁰. Bu sistemler, genel metin yapılarından varlık-olay-konsept ağları oluşturarak sıfır örnekli transfer yeteneği sunar ve yeni alanlara saniyeler içinde uyum sağlayabilir³¹. Ancak bu serbest şemalı (schema-free) esneklik, regülasyon uyumluluğu veya tıp gibi katı mantıksal kuralların kontrol edilmesi gereken hassas endüstrilerde "semantik sapmalara" ve "mantıksal doğrulanabilirlik" eksikliklerine yol açmaktadır⁴¹.

Alana Özgü Derin Entegrasyonlar

Hassas alanlarda, genel akıl yürütme yerine, etki alanına özel kısıtlamalar ve kurallarla çalışan yapılandırılmış sistemler tercih edilmektedir:

- **Tıp ve Biyomedikal:** MedMentions corpus veya UMLS referans grafları kullanılarak inşa edilen biyomedikal bilgi grafikleri, klinik kararları desteklemek için son derece katı ontolojik

sınıf kısıtlamalarına tabidir⁵⁸. Bu alandaki bilgi çıkarımlarında, ilaç-protein-semptom etkileşimleri otonom olarak çıkarılsa dahi, tıp uzmanlarının hataları kolayca yakalayabilmesi amacıyla UMLS hiyerarşileriyle kesin eşleştirme (entity linking) şart koşulmaktadır⁵⁸.

- **Hukuki Uyum ve Regülasyon (Regulatory Compliance):** EU AI Act, GDPR veya finansal türev sözleşmeleri (AI4Contracts) gibi belgelerin işlenmesinde otonom sistemler doğrudan kurallı graflar inşa etmektedir⁵⁷. Örneğin *GraphCompliance* çerçevesi, yasal yükümlülükleri basit SPO üçlülere yerine "konu-kısıt-bağlam-köşül" (subject-constraint-context-condition) çoklu ilişkisel şemalarıyla modeller⁵⁷. *PrivComp-KG* ise GDPR uyumluluğunu denetlemek için graf üzerinde SWRL (Semantic Web Rule Language) mantıksal çıkarım kurallarını koşturmaktadır⁵⁷.
- **Endüstriyel Üretim ve Hata Teşhisi:** Metalürji taşıma ekipmanları arıza raporlarından veya nükleer santral bakım belgelerinden bilgi grafikleri çıkarılırken, sistemler doğrudan "arıza zincirleri" (fault chains) oluşturacak hiyerarşik quintuple (beşli) formatlarını kullanmaktadır⁶². Bu beşli yapılar, geleneksel ilişkilerin ötesinde arıza nedeni, tetikleyici koşullar, gözlemlenen semptom, etkilenen alt sistem ve önerilen eylemi birbirine bağlayarak makine bakım ekiplerine açıklanabilir yapay zeka (XAI) sunmaktadır⁶².

Tablo 3, bu iki yaklaşımın performans, esneklik, doğruluk güvencesi ve uygulama alanları açısından temel karakterlerini karşılaştırmaktadır.

Tablo 3: Alan Bağımsız Genel Amaçlı Yöntemler ile Alana Özgü Entegrasyonların Karşılaştırmalı Analizi


Karşılaştırma Ekseni	Alan Bağımsız Genel Amaçlı Yöntemler	Alana Özgü Derin Entegrasyonlar
Temsilci Teknolojiler	AutoSchemaKG ³³ , Triplex ¹⁷ , ODKE+ ³⁸ .	GraphCompliance ⁵⁷ , Evontree ³ , OntoEKG ³⁸ .
Sıfır Örnekli Genelleme Yeteneği	Son derece yüksek; önceden tanımlanmış hiçbir şemaya ihtiyaç duymadan yeni metinleri doğrudan işler ³¹ .	Düşük; hedef etki alanının yapısal kuralları, kısıtlamaları veya ontolojik şablonları önceden tanımlanmalıdır ⁴¹ .
Graf Doğruluk ve Güvenilirlik Seviyesi	Orta-Düşük; kavramlaştırma adımlarında semantik kaymalar, halüsinasyonlar ve mantıksal çelişkiler oluşabilir ⁴¹ .	Son derece yüksek; graflar katı OWL kuralları, SHACL kısıtlamaları veya SWRL mantık katmanlarıyla denetlenir ⁵⁹ .

Kullanılan Semantik Format	Geleneksel üçlüler (SPO: Konu-Yüklem-Nesne) ve soyut konsept hiyerarşileri ²⁹ .	Çoklu ilişkisel yapılar, koşul nitelikleri, beşliler (quintuples) ve hipergraf kenarları ³⁵ .
Tipik Uygulama Alanları	Web ölçeğinde bilgi indeksleme, arama motoru optimizasyonu, genel amaçlı açık alan RAG uygulamaları ⁴ .	Biyomedikal analizler ⁵⁸ , yasal regülasyon denetimleri ⁵⁷ , endüstriyel arıza teşhis sistemleri ⁶³ .

Gerçekçi ve Uçtan Uca Otomatik Bilgi Grafiği Çıkarım Hattı

Bugünün teknolojik imkanlarıyla yapılandırılmamış çok modlu bir kurumsal belge yığınının, insan müdahalesi olmadan, yüksek kaliteli ve doğrulanabilir bir bilgi grafiği oluşturmak amacıyla tasarlanan uçtan uca otonom üretim hattı yedi temel aşamadan oluşmaktadır.

[Belge Girdisi]



1. Veri Hazırlama ve Bölümleme (Document Ingestion & Chunking)

Girdi belgeleri (PDF, HTML vb.) çok modlu işleyicilerle taranarak metin, tablo ve grafik koordinatları çıkarılır³⁵. Geleneksel RAG sistemlerinin aksine, metinler anlamsal bütünlüğü korumak için 1200 tokenlik geniş ve cümle sınırlarına duyarlı parçalara (chunks) bölünür⁷. Her parça, ileride izlenebilirlik sağlamak amacıyla sayfa ve paragraf kimlikleri içeren meta verilerle mühürlenir³⁵.

2. Dilbilimsel Çözümleme ve Yapısal Sadeleştirme

Karmaşık cümlelerin neden olduğu bilgi kayıplarını engellemek amacıyla öncelikle Mixtral tabanlı eşgönderim çözümlemesi (coreference resolution) koşturulur ve tüm zamirler (o, onlar, burası vb.) temsil ettikleri gerçek varlık isimleriyle değiştirilir⁴⁵. Ardından, ince ayarlı bir BERT-Large hiyerarşik sınıflandırıcısı cümleleri yapısal karmaşıklıklarına (basit, bileşik, karmaşık) göre ayırır⁶⁵. Karmaşık cümle yapıları, LLaMA-3.3-70B gibi modellerle anlamsal kayba uğramadan birden fazla bağımsız basit cümleye dönüştürülür⁶⁵.

3. Sokratik Sorgulama Katmanı (Interrogative Semantic Scaffolding)

Doğrudan metinden üçlü çıkarmak yerine, SocraticKG yaklaşımı doğrultusunda metin parçalarından 5W1H prensiplerine göre yapılandırılmış soru-cevap (QA) çiftleri türetilir⁴⁵. Bu ara katman, cümledeki gizli nedensel (neden), zamansal (ne zaman) ve yöntemsel (nasıl) ilişkileri açığa çıkararak bilgi kaybını önler ve çıkarım sürecini doğrulanabilir kılar⁴⁵.

4. Yüksek Hızlı Üçlü Çıkarımı (Triplet Extraction)

Elde edilen yalın soru-cevap çiftleri, sıfır örnekli ilişki çıkarımında uzmanlaşmış küçük ve maliyet etkin bir dil modeline (örneğin Triplex veya ReLiK tabanlı bir okuyucuya) beslenir¹⁴. Bu modeller, sağlanan etki alanı etiketlerini kullanarak konsept sınırlarını belirler ve SPO biçiminde (Varlık_1, İlişki, Varlık_2) veya olay yönelimli (Olay_1, İlişki, Olay_2) yapılandırılmış üçlüleri JSON formatında üretir¹⁷.

5. Global Varlık ve İlişki Çözümlemesi (Global Canonicalization)

Bağımsız metin parçalarından çıkarılan milyonlarca üçlüdeki isim varyasyonlarını (örneğin "Ronaldo", "Cristiano Ronaldo" ve "CR7") tek bir düğüm altında birleştirmek için global çözümleme adımı uygulanır³⁶. Çıkarılan varlıkların semantik gömme vektörleri çıkarılır, K-means ve HDBSCAN algoritmalarıyla kümelendir ve ardından bir LLM hakem (judge) ajan yardımıyla semantik benzerlik ile sözlüksel BM25 eşleşmeleri dengelenerek düğümler tekilleştirilir³⁶.

6. Otonom Şema Türetimi ve Kavramlaştırma

Varlıklar ve olaylar, AutoSchemaKG ve TRACE-Schema metodolojileriyle üst hiyerarşik konsept düğümlerine bağlanır²⁹. Model, her spesifik düğüm için soyutlama seviyeleri oluşturarak,

örneğin "Aspirin" düğümünü "Ağrı Kesici" ve ardından "Farmasötik Ürün" konsept sınıflarına bağlayan hiyerarşik üst kenarlar (rdf:type benzeri) üretir²⁹.

7. Doğrulama ve Aksiyom Denetimi (Validation & Repair)

Üretilen graf verisi veritabanına yazılmadan önce, SHARP benzeri otonom doğrulama ajanları ve çoklu model konsensüs filtreleri çalıştırılır³⁸. LangGraph tabanlı denetleyiciler, tanımlanan şema kurallarına uyumu kontrol eder (örneğin bir ilişkinin domain/range alanlarının tutarlılığı test edilir)³⁵. Sözdizimi hatalı SPARQL sorguları elenir ve temizlenen doğrulanmış graf verisi Neo4j gibi bir yerel grafik veritabanına aktarılır⁴¹.

Aşağıdaki Tablo 4, bu yedi aşamalı üretim hattının işleyiş detaylarını özetlemektedir.

Tablo 4: Otonom ve Uçtan Uca Bilgi Grafiği Çıkarım Hattı İş Akış Adımları

Adım No	Aşama Adı	Girdi Verisi	Gerçekleştirilen İşlem ve Algoritma	Çıktı Ürünü / Yapısı	Kullanılan Kritik Modeller
1	Bölümleme ve Çok Modlu Analiz [cite: 35, 36]	Ham Belgeler (PDF/Grafik/ Metin).	Sayfa koordinatlı metin dışı öğelerin çıkarımı; cümle sınırlarına duyarlı 1200 tokenlik bölümleme.	Provenance mühürlü metin parçaları ($c \in C$).	Çok modlu vizyon işlemcileri, Unstructure d.io entegrasyonu.
2	Sadeleştirme ve Zamir Çözümü [cite: 65]	Ham Metin Parçaları.	Mixtral ile eşgönderim çözümü; BERT-Large ile cümle karmaşıklık analizi; uzun cümlelerin bölünmesi.	Ambargosu z, yalın ve kısa cümle dizileri.	BERT-Large Classifier, Mixtral, LLaMA-3.1-8B.
3	Sokratik	Yapısal	5W1H (Kim,	Bağlamdan	Qwen-2.5-

	Sorgulama [cite: 45, 66]	Olarak Sadeleştiril miş Cümleler.	Ne, Nerede, Ne Zaman, Neden, Nasıl) şablonları üzerinden metinden otonom soru-cevap türetimi.	bağımsız, açık isimli Soru-Cevap (QA) çiftleri.	Coder-32B, Gemini-2.5- Flash.
4	Sinirsel Üçlü Çıkarımı [cite: 14, 17]	Otonom Soru-Cevap Çiftleri.	Metin dilimleri ile ilişkilerin hızlı eşleştirilme si; SPO formatında ilişkisel yapıların çıkarılması.	Yapılandırıl mış Üçlüler (S, P, O) ve hiper kenar nitelikleri.	SciPhi Triplex (3.8B), ReLiK-CIE, GLiNER2.
5	Global Varlık Çözümlem esi [cite: 36, 66]	Ham Üçlüler Dizisi.	HDBSCAN ve K-means kümelemesi ; BM25 ve yoğun semantik benzerlik entegrasyo nuyla düğüm tekkilleştirme .	Konsolide edilmiş, varyasyonla rdan arındırılmış temiz varlık seti.	LLaMA-3.3- 70B (Ajan), SBERT Gömme Modelleri.
6	Dinamik Şema İndüksiyon u [cite: 29, 36]	Tekkilleştirilm iş Varlıklar ve ilişkiler.	Düğümlerin etrafındaki komşuluk matrislerind en hareketle	Çok seviyeli konsept hiyerarşisi (TRACE-Sc hema).	LLaMA-3.1- 8B, AutoSchem aKG şemalandırı cı.

			hiyerarşik konsept tanımlama ve şema oluşturma.		
7	Mantıksal Doğrulama [cite: 41, 47]	Geçici Şema ve Graf Kayıtları.	SPARQL doğrulama döngüleri; çoklu model konsensüs oylamaları; domain/range tutarlılık kontrolleri.	Mantıksal çelişkilerde n arındırılmış, doğrulanmış üretim grafi.	LangGraph çoklu ajan yapıları, FactCheck kuralları.

Sonuçlar ve Gelecek Projeksiyonları

2024–2026 döneminde otomatik bilgi grafiği inşası, insan güdümlü statik tasarımlardan, Büyük Dil Modellerinin parametrik gücüyle beslenen, kendi şemasını otonom olarak türeten ve doğruluğunu kendi kendine denetleyen dinamik ekosistemlere evrilmiştir¹. Bu dönüşümün en önemli çıktısı, geleneksel RAG sistemlerindeki anlamsal parça kopukluğu ve çok adımlı mantıksal sorgulama yetersizliğinin, graf tabanlı veri katmanlarıyla (GraphRAG) radikal biçimde çözülmesidir⁴. Soru-cevap (QA) tabanlı aracı semantik katmanların (SocraticKG) ve cümle düzeyi sadeleştirme hatlarının (CoDe-KG) geliştirilmesi, olgusal kapsam kaybı olmaksızın yüksek graflar üretilmesini olanaklı kılmıştır⁶⁶.

İnşa süreçlerinin maliyet etkinliğini artırmak amacıyla, milyarlarca parametrelili kapalı modeller yerine, Phi3 tabanlı Triplex gibi sadece bu işe adanmış küçük dil modellerinin (SLM) ve ReLiK gibi çift yönlü eşleştircilerin kullanımı yaygınlaşmış; bu sayede bilgi grafiği oluşturma maliyetleri %98 gibi devasa oranlarda düşürülmüştür¹⁴. Bu finansal ve teknik optimizasyonlar, bilgi grafiklerini yalnızca büyük kuruluşların erişebildiği lüks bir teknoloji olmaktan çıkarıp, yerel donanımlarda bile otonom olarak koşturulabilen ölçeklenebilir yapılara dönüştürmüştür⁴.

Gelecek projeksiyonları incelendiğinde, bu alandaki ilerlemelerin üç ana ekseninde şekillendiği görülmektedir⁷¹:

1. **Otonom Reinforcement Learning Optimizasyonu:** AutoGraph-R1 örneğinde olduğu gibi, graf inşasını doğrudan bir politika (policy) öğrenimi olarak kurgulayan ve üretilen grafın kalitesini downstream RAG başarımı üzerinden ödüllendirerek optimize eden pekiştirmeli öğrenme modelleri standart hale gelecektir⁷².
2. **TERAG ve Token Verimliliği:** Graf tabanlı RAG mimarilerindeki en büyük engel olan

yüksek token tüketimi, topluluk özetlemelerini sorgu anına erteleyen LazyGraphRAG varyasyonları veya inşa maliyetlerini %89–97 oranında azaltan TERAG çerçeveleriyle çözümlenerek operasyonel sürdürülebilirlik kazanacaktır⁴.

3. **Hiper-İlişkisel ve Olay Odaklı Yapıların Standartlaşması:** Geleneksel RDF üçlülerinin sınırlarını aşan, ilişkileri zaman, mekan ve koşul nitelikleriyle sarmalayan hiper-ilişkisel bilgi grafikleri (HRKG) ile olayları da birer düğüm olarak konumlandıran otonom şemalar, yapay zeka ajanlarının kalıcı ve denetlenebilir "bellek katmanı" haline gelecektir²⁹.

Alıntılanan çalışmalar

1. LLM-empowered knowledge graph construction: A survey - arXiv, <https://arxiv.org/pdf/2510.20345?>
2. Automating the Construction of Environmental Policy Knowledge Graph with Large Language Models - MDPI, <https://www.mdpi.com/2071-1050/17/22/10282>
3. Evontree: Ontology Rule-Guided Self-Evolution of Large Language Models - arXiv, <https://arxiv.org/html/2510.26683v2>
4. Knowledge Base vs Knowledge Graph for LLM Systems (2026 Guide) - Kloia, <https://www.kloia.com/blog/knowledge-base-vs-knowledge-graph-llm>
5. GraphRAG vs. Vector RAG: The Architecture Decision Teams Make Too Late - TianPan.co, <https://tianpan.co/blog/2026-04-19-graphrag-vs-vector-rag-architecture-decision>
6. What Is GraphRAG?, <https://aras.com/en/glossary/graphrag>
7. GraphRAG: Knowledge Graph + RAG Next-Generation | Meta Intelligence, <https://www.meta-intelligence.tech/en/insight-graphrag>
8. MS-RAG: Simple and Effective Multi-Semantic Retrieval-Augmented Generation - ACL Anthology, <https://aclanthology.org/2025.emnlp-main.1151.pdf>
9. GLiNER-Relex: A Unified Framework for Joint Named Entity Recognition and Relation Extraction - arXiv, <https://arxiv.org/html/2605.10108v1>
10. urchade/GLiNER: Generalist and Lightweight Model for Named Entity Recognition (Extract any entity types from texts) - GitHub, <https://github.com/urchade/GLiNER>
11. Extract Any Entity From Text with GLiNER | by Francesco Franco | May, 2026 | AI Mind, <https://pub.aimind.so/extract-any-entity-from-text-with-gliner-c555619cc888>
12. GLiNER2 for Agentic Information Extraction - Pioneer AI by Fastino Labs, <https://pioneer.ai/blog/gliner2>
13. GLiNER2: An Efficient Multi-Task Information Extraction System with Schema-Driven Interface - arXiv, <https://arxiv.org/html/2507.18546v1>
14. ReLiK: Retrieve and Link, Fast and Accurate Entity Linking and Relation Extraction on an Academic Budget - ACL Anthology, <https://aclanthology.org/2024.findings-acl.839/>
15. ReLiK: Retrieve and Link, Fast and Accurate Entity Linking and Relation Extraction on an Academic Budget - arXiv, <https://arxiv.org/html/2408.00103v2>
16. Entity linking and relationship extraction with Relik in LlamaIndex - Neo4j, <https://neo4j.com/blog/developer/entity-linking-relationship-extraction-relik-llam>

[aindex/](#)

17. sciphi/triplex - Ollama, <https://ollama.com/sciphi/triplex>
18. SciPhi Open Sourced Triplex: A SOTA LLM for Knowledge Graph Construction Provides Data Structuring with Cost-Effective and Efficient Solutions - MarkTechPost, <https://www.marktechpost.com/2024/07/22/sciphi-open-sourced-triplex-a-sota-llm-for-knowledge-graph-construction-provides-data-structuring-with-cost-effective-and-efficient-solutions/>
19. SciPhi/Triplex - Hugging Face, <https://huggingface.co/SciPhi/Triplex>
20. [PDF] KGGen: Extracting Knowledge Graphs from Plain Text with Language Models, <https://www.semanticscholar.org/paper/KGGen%3A-Extracting-Knowledge-Graphs-from-Plain-Text-Mo-Yu/98def1a1f6a3eb10475c1c40164a1ebc02c5502a>
21. Comparison of pipelines, seq2seq models, and LLMs for rare disease information extraction, <https://pmc.ncbi.nlm.nih.gov/articles/PMC12367198/>
22. Comparison of pipeline, sequence-to-sequence, and GPT models for end-to-end relation extraction: experiments with the rare disea - arXiv, <https://arxiv.org/pdf/2311.13729>
23. On Generative Models and Joint Architectures for Document-level Relation Extraction - UKnowledge, https://uknowledge.uky.edu/cgi/viewcontent.cgi?article=1081&context=statistics_etds
24. Benchmarking zero-shot biomedical relation triplet extraction across language model architectures - ACL Anthology, <https://aclanthology.org/2025.bionlp-1.9.pdf>
25. survey of ontology learning techniques and applications | Database | Oxford Academic, <https://academic.oup.com/database/article/doi/10.1093/database/bay101/5116160>
26. The ontology learning layer cake. | Download Scientific Diagram - ResearchGate, https://www.researchgate.net/figure/The-ontology-learning-layer-cake_fig2_327297476
27. (PDF) Unsupervised Domain Ontology Learning from Text - ResearchGate, https://www.researchgate.net/publication/316501506_Unsupervised_Domain_Ontology_Learning_from_Text
28. Ontology Learning from Text: A Survey of Methods - ResearchGate, https://www.researchgate.net/publication/200044378_Ontology_Learning_from_Text_A_Survey_of_Methods
29. arXiv:2505.23628v1 [cs.CL] 29 May 2025, <https://arxiv.org/pdf/2505.23628?>
30. AutoSchemaKG Framework - Emergent Mind, <https://www.emergentmind.com/topics/autoschemakg-framework>
31. [Literature Review] AutoSchemaKG: Autonomous Knowledge Graph Construction through Dynamic Schema Induction from Web-Scale Corpora - Moonlight, <https://www.themoonlight.io/en/review/autoschemakg-autonomous-knowledge-graph-construction-through-dynamic-schema-induction-from-web-scale-corpora>

[ora](#)

32. GitHub - HKUST-KnowComp/AutoSchemaKG: This repository contains the implementation of AutoSchemaKG, a novel framework for automatic knowledge graph construction that combines schema generation via conceptualization., <https://github.com/hkust-knowcomp/autoschemakg>
33. AutoSchemaKG: Autonomous Knowledge Graph Construction through Dynamic Schema Induction from Web-Scale Corpora - arXiv, <https://arxiv.org/pdf/2505.23628>
34. [2505.23628] AutoSchemaKG: Autonomous Knowledge Graph Construction through Dynamic Schema Induction from Web-Scale Corpora - arXiv, <https://arxiv.org/abs/2505.23628>
35. Beyond Predefined Schemas: TRACE-KG for Context-Enriched Knowledge Graphs from Complex Documents - arXiv, <https://arxiv.org/html/2604.03496v1>
36. Beyond Predefined Schemas: TRACE-KG for Context-Enriched Knowledge Graph Generation - arXiv, <https://arxiv.org/html/2604.03496>
37. Beyond Predefined Schemas: TRACE-KG for Context ... - ChatPaper, <https://chatpaper.com/zh-CN/paper/264775>
38. [PDF] LLM-empowered knowledge graph construction: A survey | Semantic Scholar, <https://www.semanticscholar.org/paper/LLM-empowered-knowledge-graph-construction%3A-A-Bian/84755de35143f769ad9a65047c0b3e0a3fea32ec>
39. GenOM: Ontology Matching with Description Generation and Large Language Model - arXiv, <https://arxiv.org/html/2508.10703v2>
40. Ontology evolution from RDF streams using possibilistic axiom scoring - Semantic Web Journal, <https://www.semantic-web-journal.net/system/files/swj3781.pdf>
41. Towards Automated Ontology Generation from Unstructured Text: A Multi-Agent LLM Approach - arXiv, <https://arxiv.org/html/2604.23090v1>
42. Ontology Generation Using Large Language Models | Request PDF - ResearchGate, https://www.researchgate.net/publication/392242831_Ontology_Generation_Using_Large_Language_Models
43. [2604.23090] Towards Automated Ontology Generation from Unstructured Text: A Multi-Agent LLM Approach - arXiv, <https://arxiv.org/abs/2604.23090>
44. Ontogenia: Ontology Generation with Metacognitive Prompting in Large Language Models | Request PDF - ResearchGate, https://www.researchgate.net/publication/388444645_Ontogenia_Ontology_Generation_with_Metacognitive_Prompting_in_Large_Language_Models
45. SocraticKG: Knowledge Graph Construction via QA-Driven Fact Extraction - arXiv, <https://arxiv.org/html/2601.10003v2>
46. SocraticKG: Knowledge Graph Construction via QA-Driven Fact Extraction, <https://www.semanticscholar.org/paper/SocraticKG%3A-Knowledge-Graph-Construction-via-Fact-Choi-Jeon/088db86b76a2db0a3ed4c50366c6364e7cfea8ce>
47. Benchmarking Large Language Models for Knowledge Graph Validation - dei.unipd.it, https://www.dei.unipd.it/~silvello/papers/2026_EDBT_FactCheck.pdf
48. Benchmarking Large Language Models for Knowledge Graph Validation - arXiv,

- <https://arxiv.org/abs/2602.10748>
49. Benchmarking Large Language Models for Knowledge Graph Validation,
<https://research.aalto.fi/en/publications/benchmarking-large-language-models-for-knowledge-graph-validation/>
50. Evaluation of Pipelines for Data Integration into Knowledge Graphs - ResearchGate,
https://www.researchgate.net/publication/405132071_Evaluation_of_Pipelines_for_Data_Integration_into_Knowledge_Graphs
51. Structuring Benchmark into Knowledge Graphs to Assist Large Language Models in Retrieving and Designing Models | OpenReview,
<https://openreview.net/forum?id=49flu0yDJ4>
52. SocraticKG: Knowledge Graph Construction via QA-Driven Fact Extraction - OpenReview,
<https://openreview.net/pdf/b93f0f1826b49c6b657eab3141deac9a4da66f66.pdf>
53. SocraticKG: Knowledge Graph Construction via QA-Driven Fact Extraction | OpenReview, <https://openreview.net/forum?id=A9caGWJyDy>
54. Benchmarking Large Language Models for Knowledge Graph Validation - arXiv,
<https://arxiv.org/pdf/2602.10748>
55. TERAG: Token-Efficient Graph-Based Retrieval-Augmented Generation - arXiv,
<https://arxiv.org/html/2509.18667>
56. AutoSchemaKG: Autonomous Knowledge Graph Construction through Dynamic Schema Induction from Web-Scale Corpora - arXiv,
<https://arxiv.org/html/2505.23628v1>
57. Knowledge Graph Representations for LLM-Based Policy Compliance Reasoning - arXiv, <https://arxiv.org/pdf/2604.27713>
58. A Unified Benchmark for Evaluating Knowledge Graph Construction Methods and Graph Neural Networks - arXiv, <https://arxiv.org/html/2605.05476v1>
59. Construction of Knowledge Graphs: Current State and Challenges - Qucosa - Leipzig, <https://ul.qucosa.de/api/qucosa%3A102513/attachment/ATT-0/>
60. Knowledge Graph Representations for LLM-Based Policy Compliance Reasoning - arXiv, <https://arxiv.org/html/2604.27713v1>
61. Maruf Ahmed Mridul - Google Scholar,
<https://scholar.google.com/citations?user=ljoVmpYAAAAJ&hl=en>
62. SciGraph-LLM: Automatic Knowledge Graph Construction from Scientific Papers | Request PDF - ResearchGate,
https://www.researchgate.net/publication/404567717_SciGraph-LLM_Automatic_Knowledge_Graph_Construction_from_Scientific_Papers
63. Large Language Model with Integrated Ontology and Inference Chain Constraints for Generative Information Extraction from Metallurgical Lifting Equipment Failure Reports - ResearchGate,
https://www.researchgate.net/publication/407264987_Large_Language_Model_with_Integrated_Ontology_and_Inference_Chain_Constraints_for_Generative_Information_Extraction_from_Metallurgical_Lifting_Equipment_Failure_Reports?_tp=eyJjb250ZXh0Ijp7InBhZ2UiOiJqb3VybmFslwiclHJldmlddXNQYWdlIpudWxsLCJzZWNOaW9uIjoiGvhZGVyIiwicG9zaXRpb24iOiJwYWNlSGVhZGVyIiwic3ViUGFnZSI6I

[m92ZXJ2aWV3In19](#)

64. Construction of Knowledge Graph based on Language Model - arXiv, <https://arxiv.org/html/2604.19137v1>
65. KaushikMahmud/CoDe-KG_EMNLP_2025 - GitHub, https://github.com/KaushikMahmud/CoDe-KG_EMNLP_2025
66. [Literature Review] SocraticKG: Knowledge Graph Construction via QA-Driven Fact Extraction - Moonlight, <https://www.themoonlight.io/en/review/socratickg-knowledge-graph-construction-via-qa-driven-fact-extraction>
67. SocraticKG: Knowledge Graph Construction via QA-Driven Fact Extraction - ResearchGate, https://www.researchgate.net/publication/399808860_SocraticKG_Knowledge_Graph_Construction_via_QA-Driven_Fact_Extraction
68. GitHub - kasundularaam/socratic_rl: An end-to-end intelligent Q&A system that builds Knowledge Graphs from documents using SocraticKG and answers complex multi-hop questions with GraphRAG-R1., https://github.com/kasundularaam/socratic_rl
69. Creating Knowledge Graphs from Unstructured Data - Developer Guides - Neo4j, <https://neo4j.com/developer/genai-ecosystem/importing-graph-from-unstructured-data/>
70. Automated Knowledge Graph Construction using Large Language Models and Sentence Complexity Modelling - ACL Anthology, <https://aclanthology.org/2025.emnlp-main.783/>
71. LLM+Graph@VLDB'2025 Workshop Summary - arXiv, <https://arxiv.org/pdf/2604.02861>
72. AutoGraph-R1: End-to-End Reinforcement Learning for Knowledge Graph Construction - arXiv, <https://arxiv.org/pdf/2510.15339>