

Sürekli Bilgi Çizgesi Mimarileri: Artımlı, Zamansal ve Yerel Öğrenme Paradigmalarıyla Yıkıcı Unutmanın Önlenmesi

Gerçek dünya verilerinin dinamik, zaman damgalı ve sürekli akan yapısı, geleneksel Grafik Sinir Ağları (GNN'ler) ve Bilgi Çizgesi Gömme (KGE) modellerinin statik eğitim rejimlerine olan bağımlılığını temelden sarsmıştır. İlişkisel veri tabanları sürekli yeni düğümler, ilişkiler ve olgularla genişlerken, yapay zeka sistemlerinin geçmişte öğrendikleri bilgileri yitirmeden bu yeni verilere uyum sağlaması gerekmektedir¹. Model parametreleri bağımsız ve tekdüze dağılmayan (non-i.i.d.) sıralı veri akışları üzerinde ince ayara (fine-tuning) tabi tutulduğunda, yeni bilgileri öğrenirken eski görevlere ait parametre konfigürasyonlarını hızla ezerek tahrip eder⁴. Literatürde "yıkıcı unutma" veya "katastrofik müdahale" (catastrophic interference) olarak adlandırılan bu olgu, sistemlerin geçmiş verilere yönelik tahmin yeteneğini felce uğratarak uzun vadeli dağıtımların önündeki en büyük engel oluşturmaktadır¹.

Çizge yapılarındaki sürekli öğrenme süreçleri, öklidyen uzaylardaki (görüntü veya düz metin gibi) klasik sürekli öğrenmeden iki temel yapısal bağımlılık nedeniyle ayrılır ve çok daha karmaşık bir hal alır¹. Birincisi, düğüm düzeyindeki bağımlılıktır; çizge üzerindeki mesaj iletim (message passing) süreçleri nedeniyle, tek bir düğümün veya kenarın güncellenmesi, komşu ego-ağları boyunca dalga dalga yayılarak ilişkisel temsilleri kararsızlaştırır¹. İkincisi ise görev düzeyindeki bağımlılıktır; bu durum, zaman içinde eklenen yeni çizge alt yapılarının geçmiş çizge yapılarıyla kurduğu anlamsal ve topolojik köprüleri ifade eder¹. Dolayısıyla, bilgi çizgelerinde sürekli öğrenmeyi (CGL) gerçekleştirmek, sistemin yeni bilgiyi asimile etme kapasitesi (plastisite) ile eskiyi koruma gücü (stabilite) arasında hassas bir denge kurulmasını zorunlu kılmaktadır⁹.

Sürekli Çizge Öğrenimi Stratejilerinin Karşılaştırmalı Taksonomisi

Yıkıcı unutmayı engellemek amacıyla geliştirilen sürekli çizge öğrenimi yaklaşımları genel olarak üç ana taksonomik kategoride ele alınmaktadır: düzensizleştirme (regularization), bellek tekrarı (replay) ve parametre izolasyonu (parameter isolation)⁹. Bu stratejiler, hesaplama bütçesi, veri gizliliği ve topolojik koruma hassasiyetine göre farklı avantaj ve dezavantajlar sunmaktadır.

Düzensizleştirme Tabanlı Yöntemler

Düzensizleştirme yaklaşımları, geçmiş görevler için kritik öneme sahip parametrelerin değişimini kısıtlamak üzere optimizasyon kaybına ceza terimleri ekler⁸. Bu alandaki en köklü yöntemlerden

biri olan Elastik Ağırlık Konsolidasyonu (EWC), parametre önem derecelerini Fisher Bilgi Matrisi (FIM) aracılığıyla tahmin ederek koruma sağlar¹¹.

Ancak klasik düzensizleştirme yöntemleri, çizgelerin topolojik yapısını göz ardı eder¹³. Bu eksikliği gidermek amacıyla geliştirilen Topolojiye Duyarlı Ağırlık Koruma (TWP) modülü, parametrelerin yalnızca nihai görev performansına olan katkısını değil, aynı zamanda düğümler arası yerel mesaj iletimi ve dikkat (attention) mekanizmalarındaki topolojik yığılma süreçlerindeki rolünü de gradyanlar aracılığıyla hesaplar⁸. Önemli parametrelerin değişimini bu topolojik hassasiyete göre cezalandıran TWP, çizgenin yapısal bütünlüğünü korumada yüksek başarı göstermektedir⁸. Daha gelişmiş bir varyasyon olan Esnek Bellek Rotasyonu (FMR) ise parametre düzeyindeki kısıtlamaları, dinamik gömme ağırlıklarını kullanan yapısal düzeydeki kısıtlamalarla birleştirerek zaman adımları arasındaki bağımlılıkları minimize eder¹¹.

Bellek Tekrarı Tabanlı Yöntemler

Bellek tekrarı yöntemleri, geçmiş verilerin temsilci bir alt kümesini küçük bir tampon bellekte saklayarak yeni veri akışlarıyla birlikte modeli yeniden eğitmeyi hedefler⁸. ER-GNN gibi deneyim tekrarı modelleri; özellik ortalaması, kapsam maksimizasyonu ve topolojik etki maksimizasyonu gibi seçici stratejilerle geçmiş düğümler arasından en bilgilendirici olanları seçer⁸.

Doğrudan düğüm örnekleme yapmanın veri gizliliğini ihlal etmesi ve çizgenin global yapısını tam olarak yansıtamaması sorununa karşı, son dönemde iki yenilikçi yaklaşım öne çıkmıştır¹². Birincisi, geçmiş çizgeleri yoğunlaştırılmış sahte çizgelere dönüştüren Çekişmeli Çizge Yoğunlaştırması (ACGR) gibi üretken yöntemlerdir¹⁶. İkincisi ise örnekleme tabanlı bellek kaybını aşmak amacıyla geliştirilen, örnek veri saklamak yerine geçmiş çizgenin topolojik ve niteliksel özelliklerini kayıpsız prototip düğüm temsilleri halinde belleğe kodlayan "Debiased Lossless Memory Replay" (DeLoMe) çerçevesidir¹². Ayrıca, istemci-sunucu mimarilerinde ortaya çıkan Federal Sürekli Çizge Öğrenmesi (FCGL) senaryolarında, istemcilerin yerel verileri silmesiyle oluşan unutmayı engellemek amacıyla, sunucu tarafında geçmiş düğümlerin kritik bilgilerini barındıran bir "global özet çizge" üreten GRE-FL gibi üretken tekrar çerçeveleri de kullanılmaktadır⁸.

Parametre İzolasyonu ve Dinamik Mimariler

Parametre izolasyonu, her yeni görev için model mimarisini dinamik olarak genişleterek veya farklı parametre alt kümelerini dondurarak parametre düzeyinde çakışmaları tamamen ortadan kaldırır¹². Hiyerarşik Prototip Ağları (HPN) gibi yapılar hiyerarşik bilgi seviyelerini prototipler halinde izole ederken¹², Dinamik Uzman Karışımı (DyMoE) yaklaşımı yeni veri blokları geldikçe sisteme özelleşmiş GNN uzman katmanları ekler ve hesaplama maliyetini düşürmek için yalnızca en ilgili uzmanları aktif hale getirir¹⁴.

Sürekli Bilgi Çizgesi Gömme (CKGE) alanında ise FastKGE modeli, yeni bilgileri öğrenirken eski parametreleri tamamen donduran ve yeni varlık ile ilişkileri "Artımlı Düşük Dereceli Adaptörler" (IncLoRA) içine yerleştiren bir mekanizma sunar¹⁹. IncLoRA, varlıkların çizge içindeki yapısal önem derecelerine göre adaptörlerin rank boyutunu dinamik olarak ayarlayarak ince ayar

süresini %51 ila %68 oranında kısaltır ve ilişkisel tahmin kalitesini artırır¹⁹.

Strateji	Temel Matematiksel / Algoritmik Mekanizma	Temsili Modeller	Topolojik Avantajları	Yapısal Zayıf Yönleri
Düzensizleştirme (Regularization)	Optimizasyon kaybına parametrelerin geçmiş görev önem dereceleriyle orantılı L_{reg} cezası ekler ¹¹ .	TWP ¹⁵ , EWC ¹³ , FMR ¹¹	Bellek tamponu gerektirmez; düğümler arası mesaj iletim ve dikkat ağırlıklarını korur ¹³ .	Görev dizisi uzadıkça kısıtlamalar aşırı katılarak modelin yeni bilgileri öğrenme esnekliğini (plastisite) köreltir ¹³ .
Bellek Tekrarı (Replay)	Geçmiş görevlerden seçilen veya üretilen çizge bileşenlerini yeni veri akışıyla harmanlayarak modeli eğitir ⁸ .	ER-GNN ¹¹ , DeLoMe ¹² , GRE-FL ⁸ , GEM ⁸	Yüksek plastisite sunar; eski ve yeni varlıklar arasındaki gömme hizalamasını korur ¹¹ .	Saklanan örnek sınırlılıkları nedeniyle uzun vadeli ilişkisel yollar kaybolur; bellek tüketimi zamanla artar ¹² .
Parametre İzolasyonu (Isolation)	Yeni desenler için parametre alanını genişletir; geçmiş parametreleri dondurarak müdahaleyi sınırlar ¹² .	FastKGE ¹⁹ , HPN ¹² , DyMoE ¹⁴ , PI-GNN ¹⁴	Parametre çakışmasını sıfıra indirir; dondurulan katmanlarda unutmayı tamamen engeller ¹² .	Model boyutu ve parametre yükü sürekli büyür; eski parametrelere doğru geriye dönük bilgi aktarımı zordur ⁷ .

Artımlı ve Zamansal Bilgi Çizgesi Muhakemesi

Sürekli büyüyen bilgi çizgelerinde unutmayı engellemek kadar, gerçek zamanlı bilgi akışlarında

varlıkların zamansal değişimlerini modellemek de kritik bir öneme sahiptir. Statik çizgelerdeki artımlı güncellemelerden farklı olarak, Zamansal Bilgi Çizgeleri (TKG), her ilişkisel olguyu

(s, r, o, t) şeklinde bir özne, ilişki, nesne ve zaman damgası içeren dörtlülerle ifade eder²¹.

Bu çizgeler üzerinde yapılan Zamansal Bilgi Çizgesi Muhakemesi (TKGR) görevleri, geçmiş zaman aralıklarındaki eksik bilgileri tamamlama (interpolasyon) ve gelecek zaman adımlarındaki olguları öngörme (ekstrapolasyon) olarak ikiye ayrılır²¹. Modeller sıralı olarak eğitildiğinde, yeni zaman dilimlerindeki güncel olgular ile geçmiş anlamsal kalıplar arasında ciddi dağılım çelişkileri ortaya çıkar²¹.

Bu süreçleri yönetebilmek adına Zamansal Çizge Sürekli Öğrenmesi (TGCL) paradigması geliştirilmiştir²⁷. Geleneksel sürekli çizge öğrenimi geçmiş sınıfların veya düğümlerin zaman içinde sabit kalacağını varsayarken, TGCL gerçekçi bir yaklaşımla eski sınıfların yeni zaman dilimlerinde evrilmeye devam ettiğini kabul eder²⁷. Bu evrimi yakalamak için geliştirilen "Geleceğe Doğru Öğrenme" (LTF) çerçevesi, tüm geçmişi eğitmenin getireceği devasa maliyetten kaçınmak amacıyla, eski sınıfların güncel çizgelerdeki evrimini temsil eden küçük alt kümeler seçer²⁷. LTF, tam veri kümesi yerine bu alt kümenin kullanılmasının yaratacağı hata payının matematiksel üst sınırını (upper bound) türetir ve bu hata sınırını minimize eden seçici bir optimizasyon uygular²⁷:

$$\tilde{h}_N = \arg \min_{h \in \mathcal{H}} \epsilon(h|G_N^{old})$$

Bu formülasyonla, modelin hem eski sınıflara dair bilgilerinin güncelliği korunur hem de sınırlı bellek çerçevesinde yüksek doğruluk elde edilir²⁷.

Dinamik ve sürekli büyüyen bilgi çizgelerinde unutmayı engellemek üzere tasarlanan diğer bazı güncel mimariler şunlardır:

BAKE (Bayesian-Guided CKGE)

BAKE modeli, sürekli bilgi çizgesi gömmeyi ardışık bir Bayesyen çıkarım problemi olarak formüle eder²⁹. Geçmiş zaman diliminin gömme parametrelerini sonraki adımlar için doğal bir "Bayes önceli" (prior) olarak kabul eden model, gömme uzayının aşırı kaymasını engellemek için "sürekli kümeleme düzensizleştirme" uygular²⁹. Kontrastif kümeleme yöntemiyle çalışan bu mekanizma, semantik olarak benzer varlıkların gömme uzayında birbirine yakın kalmasını sağlayarak (küme içi sıklık) ve ilişkilerin evrilmesine kontrollü izin vererek (kümeler arası ayrılabilirlik) anlamsal tutarlılığı korur²⁹.

DGAR (Deep Generative Adaptive Replay)

Geleneksel bellek tekrarlarının tekil olguları bağımsız olarak seçmesinin ilişkisel bağlamı yok ettiğini savunan DGAR modeli, tekrar birimi olarak "Tarihsel Bağlam İstemleri"ni (HCP) kullanır²¹. Dağılım çelişkilerini aşmak için üretken bir difüzyon modeli (DM) entegre eden DGAR, geçmiş varlıkların topolojik dağılım temsillerini üretir²¹.

Üretim sürecinde, mevcut veri dağılımıyla uyumlu ortak özellikler güçlendirilirken çatışan tarihsel detaylar zayıflatılır²¹. Üretilen tarihsel temsiller (H_e^{replay}), ilişkisel GCN gibi katmanlı ağ yapılarına Derin Adaptif Tekrar (DAR) mekanizmasıyla yedirilir²¹:

$$H_e^l = \alpha H_e^{replay} + (1 - \alpha) H_e^{current,l}$$

Burada α parametresi, eski ve yeni bilgi dengesini katmanlar düzeyinde dinamik olarak yönetir²⁶.

SAGE (Scale-Aware Gradual Evolution)

Derin öğrenmedeki ölçek yasalarından esinlenen SAGE çerçevesi, bilgi çizgeleri büyüdükçe gömme boyutlarının sabit tutulmasının bilgi sıkışmasına ve katastrofik çakışmalara yol açtığını deneysel olarak kanıtlamıştır³. Çizgenin büyüme ölçeğiyle orantılı olarak gömme boyutunu (embedding dimension) kademeli olarak genişleten SAGE, iki aşamalı eğitim stratejisiyle geçmiş boyutları dondururken yeni eklenen boyutları güncel ilişkiler için optimize eder³. Bu esnek yaklaşım, terminal cihazların kısıtlı kaynaklarına göre gömme parametrelerinin paylaşılan sub-modeller halinde kırılmasına izin veren MED gibi çok boyutlu çerçevelerle de desteklenebilmektedir³¹.

Çok Boyutlu ve Kural Tabanlı Çözümler

Geleneksel KGE modellerinin aksine varlıkların zaman içinde değişen çok yönlü anlamsal rollerini modellemek için geliştirilen MF-CKGE yöntemi, sorguyla ilgisiz gürültüleri azaltmak için sorguya duyarlı dinamik gömme hizalaması yapar²³. MF-CKGE, çizge büyümesini yok sayan geleneksel değerlendirmelerin performans doğruluğunu %25 oranında abarttığını göstererek komşuluk bilgi entropisi tabanlı kısıtlamalar sunmuştur²³.

Benzer şekilde, anlamsal özellikleri ve genel çizge ağ yapısını biyolojik sinyallerden esinlenen öğrenilebilir bir maske mekanizmasıyla birleştiren CMKGE, sinaptik uyarılma ve engelleme dengesini simüle ederek önemli ağırlıkları otomatik olarak filtreler³². Anlamsal temsilleri görev kayıplarından doğrudan öğrenen görev yönlendirmeli belirteçler kullanan ETT-CKGE ise çizge üzerinde düğüm puanlama veya dolaşım yapma zorunluluğunu ortadan kaldırarak token maskeli hizalama gerçekleştirir³³.

Çizge Yapılarında Hebbian Tarzı Yerel Öğrenme Kuralları ve Biyolojik Olarak Gerçekçi Mekanizmalar

Klasik sürekli çizgiş öğrenimi yaklaşımlarının en büyük kısıtlamalarından biri, tüm ağ boyunca hata gradyanlarını geriye doğru hesaplayan ve biyolojik gerçekçilikten uzak olan küresel geri yayılım (backpropagation) algoritmasına dayanmalarıdır³⁴. İnsan beyni ise bilgiyi sinaps

seviyesinde yerel olarak işler; sinaptik bağlar, yalnızca pre-sinaptik ve post-sinaptik nöronların eş zamanlı uyarılmasına ("neurons that fire together wire together") dayanan Hebbian kurallarıyla güncellenir³⁷. Bu yerel öğrenme kurallarının çizgelere uyarlanması, geri yayılımı gerektirmeyen, paralelleştirilebilir ve yıkıcı unutmaya karşı dirençli sürekli çizge öğrenme sistemlerinin kapısını aralamıştır⁶.

Hata Geri Yayılımsız Yerel Çizge Ağları

Geri yayılımın getirdiği yüksek hesaplama maliyetini aşmak için önerilen "Hata Geri Yayılımsız Grafik Sınır Ağları" (BF-GNN'ler), yerel öğrenmeyi nöron düzeyine indirir⁶. BF-GNN mimarileri, biyolojik olarak gerçekçi Gated Linear Networks (GLN'ler) tabanlı çalışan yerel nöronlar içerir³⁴.

Bu yapının bir uzantısı olan Boosting tabanlı B^3F -GNN modeli, nöron düzeyindeki yerel öğrenmenin getirebileceği bilgi fazlalığını (redundancy) engellemek amacıyla boosting tabanlı bir çeşitlendirme mekanizması kullanır ve klasik geri yayımlı GNN'lere kıyasla daha yüksek tahmin kararlılığı sunar³⁴.

Ayrıca, analitik öğrenme teorisinden faydalananarak öğrenme sürecini özyinelemeli en küçük kareler (recursive least squares) optimizasyonu olarak formüle eden ve geri yayılım ile bellek tamponlarını tamamen devreden çıkaran AL-GNN gibi yaklaşımlar da yerel kararlılık sunmaktadır¹⁴.

İlişkisel Yapılarda Asosiyatif Öğrenme ve Termodinamik Tavlama

Yerel Hebbian güncellemeleri, düğüm gömmelerinin komşu düğümlerin gömme vektörlerinin parametrik bir Gauss karışımı olarak modellenmesine izin verir⁴⁰. Hata içermeyen asosiyatif öğrenme (error-free associative learning) olarak adlandırılan bu yöntemde, düğüm gömmeleri

gradyan hesaplaması olmaksızın, yerel geçiş olasılıkları (p_{ij}) doğrultusunda komşularıyla doğrudan hizalanır³⁹:

$$\tilde{w}_i \sim \mathcal{N}(w_i, \sigma^2 I), \quad w_j \leftarrow w_j + \eta \tilde{w}_i p_{ij}$$

Burada sinaptik gürültüyü temsil eden küresel varyans (σ^2), metalurjideki tavlama (annealing) işlemine benzer bir termodinamik yaklaşımla eğitim adımları ilerledikçe kademeli olarak azaltılır⁴⁰. Bu sayede çizge sistemi başlangıçtaki yüksek varyanslı arama alanından çıkarak kararlı ve topolojik olarak tutarlı yerel kümelenme durumlarına ulaşır³⁹. Karmaşık ağlardaki yerel bağ oluşumlarını paths of length 2 ve 3 gibi homofilik yollar üzerinden açıklayan Cannistraci-Hebb (CH) teorisi ve onun adaptif makine versiyonu olan CHA ağ otomatları da bu yerel kuralların karmaşık çizge sistemlerinde ne kadar kararlı sonuçlar verdiğini göstermektedir⁴².

Neuromorphic Sürekli Öğrenme (NCL) ve Sinaptik Metaplastisite

Neuromorphic sürekli öğrenme sistemleri, Spiking Neural Networks (SNN'ler) ve Spike-Timing-Dependent Plasticity (STDP) yerel kurallarını donanımsal düzeyde birleştirerek düşük enerjiyle sürekli öğrenmeyi hedefler⁴⁴. Sinapsların geçmiş değişim geçmişlerine göre modifiye edilme eşiklerini ayarlayan "sinaptik metaplastisite" ilkelerinden esinlenen bu sistemlerde, ağırlık değişimleri yerel aktiviteye göre sınırlandırılır⁴⁴.

Bu çerçevede önerilen Hebbian Öğrenme Tabanlı Ortogonal Projeksiyon (HLOP) yöntemi, nöronlar arasındaki lateral (enlemesine) geri beslemeli bağlantıları kullanarak veri akışından yerel aktivite bileşenlerini çıkarır⁴⁷. HLOP, yeni sinaptik güncellemeleri geçmiş görevlerin veri uzayına tamamen dik (ortogonal) olan bir alt uzaya yansıtarak, bellek tekrarına ihtiyaç duymadan sıfıra yakın unutmama performansı sergiler⁴⁷. Benzer şekilde, Hebbian Descent teorisi de çıkış katmanındaki aktivasyon fonksiyonunun türevini yok sayan alternatif bir yerel log-olabilirlik kaybı sunarak sature olmuş nöronlardaki gradyan tıkanmalarını çözer ve sürekli öğrenme kapasitesini artırır⁴⁸.

Ajan Belleklerinde Doğrulama Kapılı Hebbian Öğrenmesi: Kairos

LLM tabanlı otonom ajanların uzun vadeli bellek sistemleri olarak kullanılan bilgi çizgelerinde, saf denetimsiz Hebbian öğrenmesi kullanmak ciddi bir risk barındırır; sistem doğru veya yanlış ayrımı yapmaksızın her uyarımda kenarları güçlendireceği için halüsinasyonları kalıcı hale getirebilir³⁸. Bu sorunu çözmek için geliştirilen *Kairos* mimarisi, bilgi çizgeleri üzerinde üç temel yerel operasyonu formüle eder³⁸:

1. **Kenar Güçlendirme (LTP Analogu):** Başarılı çıkarım yollarında yer alan ilişkisel kenarların ağırlıklarını artırır³⁸.
2. **Zamansal Sönümleme (LTD Analogu):** Kullanılmayan veya düşük başarı gösteren yolları zaman içinde zayıflatarak bellek alanını temizler³⁸.
3. **Yeni Kenar Oluşumu (Emergent Connection):** Muhakeme esnasında keşfedilen anlamsal ilişkiler üzerinden çizgeler üzerinde yeni kestirme yollar açar³⁸.

Kairos'un getirdiği en kritik yenilik, **Doğrulama Kapılı Öğrenme** (validation-gated learning) mekanizmasıdır³⁸. Çizge üzerindeki güncellemeler serbestçe yapılmaz; yalnızca mantıksal tutarlılık, olgusal temellendirme (grounding), anlamsal yenilik ve hedef hizalaması kriterlerinden oluşan çok boyutlu bir süzgeçten geçen çıkarımlar çizgeye kalıcı olarak kodlanır³⁸. Kairos, bu süreçte yenilik (novelty) ile doğruluk (correctness) boyutlarının birbirine dik (orthogonal) olduğunu ve bu iki puanın ortalamasının alınmasının performansı düşürdüğünü saptayarak bu boyutları bağımsız kapılar halinde yönetir⁴⁹.

Fazör Çizgeleri ve Uyku Rejimi Konsolidasyonu

Yerel üç faktörlü plastisite kurallarını dinamik sistemlerle birleştiren *Phasor Agents* çerçevesi, latent ajan durumlarını Stuart-Landau osilatörlerinden oluşan ağırlıklı bir fazör çizgesi olarak modeller³⁶. Bu sistemde düğümler karmaşık sayısal değerler taşır ve sinaptik ağırlık güncellemeleri, yerel uygunluk izleri (eligibility traces) ile küresel nöromodülatörlerin etkileşimiyle gerçekleşir³⁶.

Ajanın çevreyle etkileşime girip geçici sinaptik etiketler (tags) biriktirdiği "Uyanıklık" (Wake)

fazını, bu etiketlerin gürültü eşliğinde yerel Hebbian kurallarıyla kalıcı ağırlıklara dönüştürüldüğü "Derin Uyku" (Deep Sleep) ve "REM Uykusu" rezonans fazları takip eder¹⁷. Bu yapay uyku-konsolidasyon döngüsü, sistemin geçmişte öğrendiği topolojik desenleri kararlı bir şekilde korumasını sağlar¹⁷.

Sürekli Çizge Öğrenmesinde Güncel En İyi Teknolojiler (SOTA) ve Karşılaştırmalı Analizler

Sürekli çizge öğrenmesi ve artımlı bilgi çizgesi tamamlama modellerinin performansını standart kurallarla ölçmek için CGLB (Sürekli Çizge Öğrenimi Karşılaştırma Ölçütü) gibi standartlaştırılmış veri ve görev kümeleri kullanılmaktadır¹⁸.

Aşağıdaki tablolar, güncel literatürdeki en başarılı modellerin anlamsal yaklaşımlarını, matematiksel mekanizmalarını ve standart test setleri (ICEWS, FB15K, CoraFull vb.) üzerindeki performans çıktılarını ve hesaplama maliyetlerini özetlemektedir.

Tablo 1: Sürekli Çizge Öğrenimi Modellerinin Teknik Özellikleri

Model Sınıfı	Temsili Model	Temel Matematiksel Çerçeve ve Koruma Fonksiyonu	Çizge Yapısı ve Akış Parametreleri	Kaynak
Düzensizleştirme	TWP [cite: 15]	$\mathcal{L}_{TWP} = \mathcal{L}_{task}$ [cite: 13, 15]	Düğüm düzeyinde yerel dikkat katsayıları ve mesaj iletim topolojisini doğrudan korur ¹³ .	[cite: 15]
Üretken Tekrar	DGAR [cite: 26]	$L_t = L_{t,c} + (L_{t,r} \text{ üretken bağlam replay kaybı})^{26}$	HCP bağlam istemleri üzerinden zaman dilimlerini difüzyon tabanlı modelleyerek dağılım	[cite: 21, 26]

			çakışmalarını çözer ²¹ .	
Parametre İzolasyonu	FastKGE [cite: 19]	$\text{Rank}(e) =$ (Dinamik rank ölçeklemesi) ¹⁹	Yeni varlıkları ve yapısal değişimleri dondurulmuş ana ağın yanındaki IncLoRA katmanlarına izole eder ¹⁹ .	[cite: 19]
Bayesyen Sürekli	BAKE [cite: 29]	Bayes posterior güncellemesi + Kontrastif anlamsal küme kayı ²⁹	Küme içi sıklık ve kümeler arası ayrılabilirlik kurallarıyla gömme uzayının kaymasını önler ²⁹ .	[cite: 29]
Artımlı Yerel	Kairos [cite: 50]	LTP (güçlendirme) + LTD (temporal sönümlleme) + Doğrulama Kapısı ³⁸	LLM ajanları için halüsinasyonu engelleyen, doğruluk ve yenilik odaklı dinamik anlamsal ağ günceller ⁴⁹ .	[cite: 50]

Tablo 2: SOTA Modellerinin Performans ve Hesaplama Verimliliği Profili

Model	Test Veri Kümesi	MRR (%)	Hits@10 (%)	Zaman / Hesapla ma Maliyeti (Görev	Yapısal Katkı Oranı / Özellikle	Kaynak
-------	---------------------	---------	----------------	--	--	--------

				Başına)	r	
Retrain (Sıfırdan)	ICE14	49.80	—	553.48 saniye (Aşırı yüksek hesaplama yükü) ²⁶	Teorik performans üst sınırı; her güncellemede tüm çizgeyi eğitir ²¹ .	[cite: 26]
DGAR (k=25)	ICE14	49.90	—	5.21 saniye (Dehşet verici hız artışı) ²⁶	Sıfırdan eğitmeyi geride bırakarak zaman maliyetini %99 oranında düşürür ²⁶ .	[cite: 26]
DGAR (k=5)	ICE14	44.93	—	4.00 saniye (Ultra hızlı/Düşük bellek) ²⁶	Kısıtlı bellek bütçesinde bile standart deneyim tekrarlarını geride bırakır ²⁶ .	[cite: 26]
SAGE	CKG Ölçütleri	23.10	39.80	Dinamik gömme genişletme maliyeti (+1.38% MRR kazancı) ³	Gömme boyutunu çizgenin büyüme hızına göre ayarlayarak çakışmay	[cite: 3, 30]

					ı önler ³ .	
FastKGE	FB-CKGE	22.50	35.40	Eğitim süresinde n %51 ila %68 oranında tasarruf sağlar ¹⁹	Tam parametreye eğitimi yerine düşük ranklı IncLoRA ağırlıklarını günceller ¹⁹ .	[cite: 19]
IncDE	FB15K-237	24.80	41.20	İki aşamalı sıralı eğitim (Hiyerarşik damıtma dahil) ²	Geleneksel damıtma yöntemlerine kıyasla MRR skorunda %0.2 - %6.5 artış sağlar ² .	[cite: 2, 54]

Açık Problemler ve Gelecek Araştırma Yönleri

Sürekli çizge öğrenmesi alanındaki yoğun çalışmalara rağmen, gerçek dünya bilgi çizgelerinin karmaşıklığı nedeniyle bazı yapısal problemler henüz tam olarak çözülmemiştir.

Çizgelerde Topolojik ve Spektral Sapma (Structural Drift)

Mevcut sürekli öğrenme yaklaşımlarının büyük bölümü, modellerin başarısını yalnızca bağ tahmini (MRR) veya düğüm sınıflandırma doğruluğu gibi yüzeysel metriklerle ölçmektedir⁵⁵.

Ancak, çizgenin tüm ilişkisel ağını tampon bellek sınırlılıkları nedeniyle kısmi pencerelerle (S_t) eğitmek, çizgenin spektral özellikleri, doğal bağlantı katsayıları, topluluk sınırları ve merkezilik rolleri gibi global topolojik niteliklerini zamanla tahrip eder⁵⁵.

Bu gizli topolojik sapma, modelin doğruluğu yüksek görünse dahi, çok adımlı (multi-hop) ilişkisel muhakeme gerektiren karmaşık sorgularda sistemin aniden başarısız olmasına ve yapısal

çökmelere yol açmaktadır⁵⁵.

Yerel Öğrenme Kurallarında Bilgi Tekrarı ve Temsil Daralması (Representation Redundancy)

Geri yayılsız BF-GNN ve yerel Hebbian tabanlı nöral ağlar, donanımsal paralelleştirme ve enerji verimliliği açısından devrimsel nitelikte olsa da, yerel öğrenme kuralları doğası gereği ortak uyarım yollarını aşırı derecede güçlendirmeye eğilimlidir³⁴. Küresel bir hata sinyalinin koordinasyonu olmaksızın sadece yerel komşuluk etkileşimleriyle güncellenen düğüm gömmeleri, zamanla birbirine aşırı benzer temsiller üretmeye başlar³⁴.

Bu "temsil daralması" ve bilgi fazlalığı, çizgenin ayırt edici gücünü azaltarak modelin sınıflandırma ve ilişkisel tamamlama kapasitesini, küresel geri yayılımla eğitilen klasik GNN'lerin altına çekmektedir³⁴.

Çevresel Kestirme Yollar (Shortcuts) ve Görev-ID Sızıntısı

Güncel sürekli çizge öğrenme protokollerinde ciddi bir değerlendirme kusuru bulunmaktadır⁵⁷. Mevcut veri setlerinin sınıf-artımlı parçalama yöntemleri, modellerin ilişkilerin gerçek semantik mantığını (invariant rationales) öğrenmek yerine, görev sınırlarının topolojik özelliklerinden faydalanan sahte kestirme yollar (shortcuts) keşfetmesine izin verir⁵⁷.

Görev kimliğinin (Task-ID) sızmasına benzeyen bu yapısal hata nedeniyle, model yeni bir görevle karşılaşır eski sahte ilişkiler çöktüğünde katastrofik düzeyde unutma yaşar⁵⁷. Bu nedenle sürekli çizge öğrenimini, sahte özellikleri eleyerek değişmez mantıksal gerekçeleri (invariant rationales) yakalayacak şekilde yeniden formüle etmek gerekmektedir⁵⁸.

Dağıtık ve Sınırlandırılmış Ortamlarda Küresel Unutma

Federal sürekli çizge öğrenimi (FCGL) senaryolarında, verilerin coğrafi veya donanımsal olarak izole edilmiş istemciler üzerinde bulunması, global modelin güncellenmesi sırasında "küresel katastrofik unutma" (global catastrophic forgetting) adı verilen yeni bir kriz yaratır⁸. İstemciler yerel çizgelerindeki değişiklikleri yaparken küresel model agregasyonu (birleştirme) sırasında yerel gradyanların birbiriyle çakışması, sunucudaki modelin geçmiş istemci desenlerini tamamen kaybetmesine yol açar⁸.

Üretken küresel özet çizgeler üreten GRE-FL gibi çözümler geliştirilmiş olsa da, veri gizliliğini ihlal etmeden ve sınırlandırılmış mobil cihazların kısıtlı bellek-bant genişliği sınırlarını zorlamadan küresel koordinasyonu sağlamak hala önemli bir açık araştırma konusudur⁸.

Alıntılanan çalışmalar

1. Continual Graph Learning: A Survey - arXiv, <https://arxiv.org/html/2301.12230v2>
2. Towards Continual Knowledge Graph Embedding via Incremental Distillation - AAAI Publications, <https://ojs.aaai.org/index.php/AAAI/article/view/28722/29396>
3. SAGE: Scale-Aware Gradual Evolution for Continual Knowledge Graph Embedding - arXiv, <https://arxiv.org/html/2508.11347v1>
4. What is Catastrophic Forgetting? - IBM,

- <https://www.ibm.com/think/topics/catastrophic-forgetting>
5. Bayesian continual learning and forgetting in neural networks - Indico, https://indico.cern.ch/event/1514154/contributions/6620196/attachments/3106713/5566976/MESU_UQ_KellianCottart.pdf
 6. Luca PASA | PostDoc Position | Ph.D. in Mathematical Sciences | University of Padua, Padova | UNIPD - ResearchGate, <https://www.researchgate.net/profile/Luca-Pasa-2>
 7. (PDF) Continual Graph Learning: A Survey - ResearchGate, https://www.researchgate.net/publication/367557778_Continual_Graph_Learning_A_Survey
 8. Overcoming Catastrophic Forgetting in Federated Continual Graph Learning for Resource-Limited Mobile Devices - IEEE Computer Society, <https://www.computer.org/csdl/journal/tm/2025/10/11015764/273BwSANANq>
 9. Continual Learning on Graphs: A Survey - arXiv, <https://arxiv.org/pdf/2402.06330>
 10. Continual Graph Learning with Knowledge-Augmented Replay: A Case for Ethereum Phishing Detection - MDPI, <https://www.mdpi.com/2079-9292/14/17/3345>
 11. Flexible Memory Rotation (FMR): Rotated Representation with Dynamic Regularization to Overcome Catastrophic Forgetting in Continual Knowledge Graph Learning - IEEE Computer Society, <https://www.computer.org/csdl/proceedings-article/bigdata/2024/10825244/23ylcraYHa8>
 12. Graph continual learning with debiased lossless memory replay - Institutional Knowledge (InK) @ SMU, https://ink.library.smu.edu.sg/context/sis_research/article/10911/viewcontent/FAIA_392_FAIA240692.pdf
 13. Overcoming Catastrophic Forgetting in Graph Neural Networks | Request PDF, https://www.researchgate.net/publication/363390186_Overcoming_Catastrophic_Forgetting_in_Graph_Neural_Networks
 14. Continual Learning on Dynamic Graphs via Parameter Isolation - Semantic Scholar, <https://www.semanticscholar.org/paper/Continual-Learning-on-Dynamic-Graphs-via-Parameter-Zhang-Yan/12b20c26a718a2aa2457b3908f107c0e74637a45>
 15. Overcoming Catastrophic Forgetting in Graph Neural Networks - AAAI Publications, <https://ojs.aaai.org/index.php/AAAI/article/view/17049/16856>
 16. Continual Graph Learning: From Experience Replay to Replay-Free Methods - University of Liverpool Repository, https://livrepository.liverpool.ac.uk/3197812/1/201592936_Mar31%20%28002%29.pdf
 17. Overcoming Catastrophic Forgetting in Federated Continual Graph Learning for Resource-Limited Mobile Devices - ResearchGate, https://www.researchgate.net/publication/392142858_Overcoming_Catastrophic_Forgetting_in_Federated_Continual_Graph_Learning_for_Resource-Limited_Mobile_Devices
 18. UConn-DSIS/Survey-of-Continual-Learning-on-Graphs - GitHub,

- <https://github.com/UConn-DSIS/Survey-of-Continual-Learning-on-Graphs>
19. Fast and Continual Knowledge Graph Embedding via Incremental LoRA - IJCAI, <https://www.ijcai.org/proceedings/2024/243>
 20. Fast and Continual Knowledge Graph Embedding via Incremental LoRA - IJCAI, <https://www.ijcai.org/proceedings/2024/0243.pdf>
 21. A Generative Adaptive Replay Continual Learning Model for Temporal Knowledge Graph Reasoning - ACL Anthology, <https://aclanthology.org/2025.acl-long.537.pdf>
 22. Lifelong knowledge graph embedding via diffusion model - PubMed, <https://pubmed.ncbi.nlm.nih.gov/41610787/>
 23. Fast and Continual Knowledge Graph Embedding via Incremental LoRA - ResearchGate, https://www.researchgate.net/publication/382789499_Fast_and_Continual_Knowledge_Graph_Embedding_via_Incremental_LoRA
 24. Temporal Knowledge Graph Reasoning - Emergent Mind, <https://www.emergentmind.com/topics/temporal-knowledge-graph-reasoning-tkgr>
 25. Temporal Extrapolation and Knowledge Transfer for Lifelong Temporal Knowledge Graph Reasoning - ACL Anthology, <https://aclanthology.org/2023.findings-emnlp.448.pdf>
 26. A Generative Adaptive Replay Continual Learning Model for Temporal Knowledge Graph Reasoning - ACL Anthology, <https://aclanthology.org/2025.acl-long.537/>
 27. A Selective Learning Method for Temporal Graph Continual Learning - arXiv, <https://arxiv.org/pdf/2503.01580>
 28. ICML Poster A Selective Learning Method for Temporal Graph Continual Learning, <https://icml.cc/virtual/2025/poster/46118>
 29. Learning to Evolve: Bayesian-Guided Continual Knowledge Graph Embedding - arXiv, <https://arxiv.org/html/2508.02426v3>
 30. (PDF) SAGE: Scale-Aware Gradual Evolution for Continual Knowledge Graph Embedding, https://www.researchgate.net/publication/394524473_SAGE_Scale-Aware_Gradual_Evolution_for_Continual_Knowledge_Graph_Embedding
 31. Croppable Knowledge Graph Embedding - ACL Anthology, <https://aclanthology.org/2025.acl-long.579.pdf>
 32. Orchestrating Plasticity and Stability: A Continual Knowledge Graph Embedding Framework with Bio-Inspired Dual-Mask Mechanism - GitHub, <https://raw.githubusercontent.com/mlresearch/v260/main/assets/song25a/song25a.pdf>
 33. ETT-CKGE: Efficient Task-driven Tokens for Continual Knowledge Graph Embedding - AWS, https://ecmlpkdd-storage.s3.eu-central-1.amazonaws.com/preprints/2025/research/preprint_ecml_pkdd_2025_research_465.pdf
 34. Local Learning with Boosting-based Backpropagation-Free Graph Neural Networks, https://www.researchgate.net/publication/404523131_Local_Learning_with_Boosting-based_Backpropagation-Free_Graph_Neural_Networks
 35. Local Learning with Boosting-based Backpropagation-Free Graph Neural

- Networks - Unipd,
<https://www.research.unipd.it/retrieve/ce8a71f9-b086-490c-8040-65a09e9392b8/s10994-026-07041-x.pdf>
36. Phasor Agents: Oscillatory Graphs with Three-Factor Plasticity and Sleep-Staged Learning, <https://arxiv.org/html/2601.04362v1>
 37. Hebbian Learning: Theory and Applications - Emergent Mind,
<https://www.emergentmind.com/topics/hebbian-learning>
 38. Validation-Gated Hebbian Learning for Adaptive Agent Memory - CEUR-WS.org,
<https://ceur-ws.org/Vol-4162/paper4.pdf>
 39. Hebbian Graph Embeddings - OpenReview,
<https://openreview.net/forum?id=H1ep5TNKwr>
 40. US20200342523A1 - Link prediction using hebbian graph embeddings - Google Patents, <https://patents.google.com/patent/US20200342523A1/en>
 41. Hebbian Graph Embeddings - arXiv, <https://arxiv.org/pdf/1908.08037>
 42. Adaptive Cannistraci-Hebb Network Automata Modelling of Complex Networks for Path-based Link Prediction,
https://proceedings.neurips.cc/paper_files/paper/2025/hash/396c99af13c9a2e867172bea3e6b6d42-Abstract-Conference.html
 43. NeurIPS Poster Adaptive Cannistraci-Hebb Network Automata Modelling of Complex Networks for Path-based Link Prediction,
<https://neurips.cc/virtual/2025/poster/116787>
 44. Continual Learning With Neuromorphic Computing: Foundations, Methods, and Emerging Applications - ResearchGate,
https://www.researchgate.net/publication/393737640_Continual_Learning_with_Neuromorphic_Computing_Foundations_Methods_and_Emerging_Applications
 45. Continual Learning with Hebbian Plasticity in Sparse and Predictive Coding Networks: A Survey and Perspective - arXiv, <https://arxiv.org/html/2407.17305v2>
 46. Continual learning with hebbian plasticity in sparse and predictive coding networks: a survey and perspective - ResearchGate,
https://www.researchgate.net/publication/387138358_Continual_learning_with_hebbian_plasticity_in_sparse_and_predictive_coding_networks_a_survey_and_perspective
 47. HEBBIAN LEARNING BASED ORTHOGONAL PROJECTION FOR CONTINUAL LEARNING OF SPIKING NEURONS - ICLR Proceedings,
https://proceedings.iclr.cc/paper_files/paper/2024/file/46b1be2b90c6addc84efdf5d7e90eebc-Paper-Conference.pdf
 48. Hebbian Descent: A Unified View on Log-Likelihood Learning | Neural Computation,
<https://direct.mit.edu/neco/article/36/9/1669/124060/Hebbian-Descent-A-Unified-View-on-Log-Likelihood>
 49. <https://openreview.net/forum?id=EN9VRTnZbK>
 50. Validation-Gated Hebbian Learning for Adaptive Agent Memory - OpenReview,
<https://openreview.net/pdf?id=EN9VRTnZbK>
 51. Phasor Agents: Oscillatory Graphs with Three-Factor Plasticity and Sleep-Staged Learning - arXiv, <https://arxiv.org/pdf/2601.04362>

52. DRIFT: A Benchmark for Task-Free Continual Graph Learning with Continuous Distribution Shifts - arXiv, <https://arxiv.org/html/2605.12998v2>
53. CGLB: Benchmark Tasks for Continual Graph Learning, https://proceedings.neurips.cc/paper_files/paper/2022/hash/548a41b9cac6f50dccb7e63e9e1b1b9b-Abstract-Datasets_and_Benchmarks.html
54. Towards Continual Knowledge Graph Embedding via Incremental Distillation | Proceedings of the AAAI Conference on Artificial Intelligence, <https://ojs.aaai.org/index.php/AAAI/article/view/28722>
55. Recent developments in incremental learning for graph-based recommender systems from a complex network perspective - Emerald Insight, <https://www.emerald.com/ftinr/article/20/3/177/1379965/Recent-developments-in-incremental-learning-for>
56. Rethinking Continual Knowledge Graph Embedding: Benchmarks and Analysis, <https://scholar.xjtu.edu.cn/en/publications/rethinking-continual-knowledge-graph-embedding-benchmarks-and-ana/>
57. Can LLMs Alleviate Catastrophic Forgetting in Graph Continual Learning? A Systematic Study | OpenReview, <https://openreview.net/forum?id=ZKkeA1G935>
58. Exploring Rationale Learning for Continual Graph Learning - AAAI Publications, <https://ojs.aaai.org/index.php/AAAI/article/view/34263/36418>