

2025-2026 Nöro-Sembolik Yapay Zeka Araştırmalarının Mevcut Durumu: Dinamik Bilgi Çizgeleri ve Öğrenilmiş İlişkisel Yapılar

Giriş ve Paradigma Değişiminin Teorik Temelleri

Yapay zeka araştırmalarının tarihsel gelişimi içerisinde "üçüncü yaz dönemi" olarak adlandırılan günümüz süreci, makine öğreniminin veri odaklı, istatistiksel gücü ile sembolik yapay zekanın mantıksal, kural tabanlı yapılarının benzeri görülmemiş bir entegrasyonuna sahne olmaktadır¹. Nöro-sembolik yapay zeka (NeSy) olarak bilinen bu alan, 2025 ve 2026 yılları itibarıyla yalnızca teorik bir araştırma konusu olmaktan çıkmış, büyük ölçekli dil modellerinin (LLM) yapısal sınırlarını aşmak ve kurumsal uygulamalarda deterministik güvenilirlik sağlamak adına vazgeçilmez bir mimari standart haline gelmiştir³. Bu dönemin en belirgin paradigma değişimi, bilgi çizgelerinin (Knowledge Graphs - KG) statik, dışsal birer veri tabanı olarak kullanılmasından vazgeçilerek; çıkarım süreci boyunca topolojisi öğrenilen, güncellenen ve çok boyutlu olarak evrilen "dinamik bilgi çizgelerine" (Dynamic Knowledge Graphs - DKG) geçiş yapılmasıdır⁵.

Kahneman'ın ikili süreç teorisinden ilham alan nöro-sembolik sistemler, sinir ağlarının hızlı, paralel ve sezgisel "Sistem 1" düşünme yeteneği ile sembolik mantığın yavaş, ardışık ve kasıtlı "Sistem 2" yeteneklerini birleştirir⁷. Salt derin öğrenme yaklaşımları, milyarlarca parametreye sahip olsalar dahi temel istatistiksel korelasyonların ötesine geçmekte zorlanmakta, deterministik garantiler verememekte ve "halüsinasyon" olarak bilinen yapısal hatalar üretmektedir³. Öte yandan, tamamen sembolik sistemler olan uzman sistemler (expert systems) ve geleneksel ontolojiler, gerçek dünyanın gürültülü ve belirsiz doğası karşısında kırılgan bir yapı sergilemekte ve bilgi mühendisliği açısından yüksek maliyetler gerektirmektedir¹⁰. Bu iki zıt kutbun sentezini amaçlayan güncel araştırmalar, bilginin yalnızca depolandığı değil, aynı zamanda bağlama göre yeniden yapılandırıldığı ajan tabanlı sistemlere yönelmiştir.

Bu kapsamlı rapor, 2025 ve 2026 yıllarında yayımlanan dönüm noktası niteliğindeki makaleleri, alanın öncüsü konumundaki araştırma gruplarını, ticari ölçekte kanıtlanmış endüstriyel uygulamaları ve henüz çözülmemiş temel problemleri sistematik bir bütünlük içerisinde incelemektedir. Analiz, dinamik grafik belleklerinden türevlenebilir mantık programlamaya, sürekli öğrenme çerçevelerinden üretici akış ağlarına kadar geniş bir yelpazeyi kapsayarak, nöro-sembolik entegrasyonun mevcut durumunu derinlemesine ortaya koymaktadır.

Statik Yapılardan Dinamik ve Evrimleşen Bilgi

Çizgelerine Geçiş

Geleneksel olarak, bilgi çizgeleri üzerinden yapılan çok adımlı (multi-hop) mantıksal çıkarım ve Geri Çıkarma Artırımı Üretim (Retrieval-Augmented Generation - RAG) süreçleri statik bir yapıya dayanmaktaydı. Bu geleneksel yaklaşımda modeller, değiştirilemez nitelikteki üçlülere (özne-ilişki-nesne) dışarıdan alır ve k-sıçramalı (k-hop) algoritmalarla bağlamı genişletirdi. Ancak bu statik yöntem, günümüzün karmaşık yapay zeka görevlerinde aşırı bilgi çekilmesine (over-retrieval), bağlam penceresinin gereksiz gürültü ile dolmasına, öngörülemeyen hesaplama gecikmelerine ve maliyet artışlarına yol açmaktadır¹².

Dinamik bilgi çizgeleri, bu darboğazı aşmak için geliştirilmiş, zamansal ve bağlamsal değişimleri hesaba katan, öğrenme süreciyle eşzamanlı olarak topolojisini güncelleyen hesaplamalı yapılardır⁶. Dinamik çizgelerde düğümler ve kenarlar yalnızca veri parçacıklarını değil, aynı zamanda yapay zeka ajanının inanç durumlarını, işlem yeteneklerini ve temporal (zamansal) bağlamları temsil eder. Çizge üzerinde "bağlam inşası" artık bir ön hazırlık aşaması değil; hangi düğümlerin genişletileceğine, hangi kanıtların silineceğine ve hangi mantıksal yolların izleneceğine karar verilen sıralı bir karar verme problemine (sequential decision process) dönüşmüştür¹⁴.

Ajan Tabanlı Dinamik Bağlam İnşası: CLAUSE Mimarisi

Bilgi çizgesi üzerinden yapılan bağlam mühendisliğini ve yapı öğrenimini otonom hale getiren en çarpıcı gelişmelerden biri 2025 yılında yayımlanan CLAUSE (Context Learning And Understanding for Symbolic Execution) çerçevesidir¹². Sabit ve kurala dayalı çizge genişletme yöntemlerinin yerini alan bu mimari, görevleri üç uzmanlaşmış nöro-sembolik ajana böler ve grafiğin yapısını dinamik olarak optimize eder.

CLAUSE sistemindeki ilk birim olan Alt-Çizge Mimarı (Subgraph Architect), sorgunun kök düğümlerinden başlayarak hangi kenarların bilgi çizgisine dahil edileceğine karar verir. Sabit bir derinliğe inmek yerine, her bir kenar için bilgi kazancını (information gain) ve token maliyetini tahmin eden nöral bir sinyal kullanır; böylece gereksiz genişlemeler engellenir¹⁵. Ardından, Yol Gezini (Path Navigator) devreye girer. Bu ajan, çok amaçlı bir arama algoritması yürüterek çizge üzerinde potansiyel akıl yürütme yollarını keşfeder; yolun kalitesi düştüğünde veya mantıksal çıkarım çıkmaza girdiğinde geri dönüş (backtracking) uygulayarak farklı ilişkisel düğümlere yönelir¹⁷. Son olarak, Bağlam Küratörü (Context Curator), genişletilmiş ve yolları belirlenmiş dinamik alt-çizgeden yalnızca kanıt niteliği taşıyan düğümleri seçer, böylece dil modelinin kısıtlı bağlam penceresi aşılmadan kaynağı doğrulanabilir (provenance-preserving) bir yanıt üretilmesi sağlanır¹⁶.

Bu üç ajan, birbirlerinden bağımsız hareket etmek yerine, araştırmacıların geliştirdiği Lagrangian Kısıtlı Çoklu Ajan Proksimal Politika Optimizasyonu (LC-MAPPO) algoritması ile ortaklaşa eğitilir¹⁵. Gecikme süresi ve token maliyeti birer ceza katsayısı olarak sisteme entegre edildiğinden, ajanlar çalışma zamanında yeni baştan eğilmeye gerek kalmadan doğruluk-maliyet dengesini otonom olarak kurar. Kapsamlı ampirik sonuçlar, CLAUSE mimarisinin HotpotQA ve MetaQA veri setlerinde mevcut tüm statik çizge tabanlı RAG

yöntemlerini geride bıraktığını göstermektedir.

Model / Mimari	Kullanılan Yöntem	Gecikme Süresi (Latency)	Bağlam Büyüklüğü (Edge Growth)	Tam Eşleşme (EM@1) Başarısı
Geleneksel GraphRAG	Statik k-sıçrama, Önceden Tanımlı Kurallar	Yüksek ve Öngörülemez	Kontrolsüz Büyüme	Temel Seviye
SFT (Supervised Fine-Tuning)	Nöral Arama ve Statik Eşleştirme	Orta	Orta	Temel Seviyenin %15 Üzerinde
StructGPT (GPT-4 Tabanlı)	Sıralı İstem (Prompting), Statik KG	Çok Yüksek	Aşırı Şişkin	Temel Seviyenin %22 Üzerinde
CLAUSE (LC-MAPPO)	Ajan Tabanlı Dinamik Optimizasyon	%18.6 Daha Düşük	%40.9 Daha Az Düğüm/Kenar	%39.3 Daha Yüksek [cite: 12, 18]

Akış Ağları (GFlowNets) ile Çizge Üzerinde Yapı Öğrenimi

Dinamik bilgi çizgelerinin inşasında ve mantıksal yolların keşfedilmesinde, Yoshua Bengio ve Mila araştırma grubu tarafından geliştirilen Üretici Akış Ağları (Generative Flow Networks - GFlowNets) belirleyici bir rol oynamaktadır¹⁹. Klasik takviyeli öğrenme (Reinforcement Learning) algoritmaları yalnızca ödülü maksimize eden tek bir optimal duruma odaklanırken, GFlowNets ayrık kompozisyonel yapıları, hedef ödül dağılımıyla orantılı olasılıklarla örnekleyen (amortized sampling) bir yaklaşım sunar²⁰. Bu özellik, bilimsel keşiflerde ve karmaşık çizge tabanlı mantık yürütme süreçlerinde, sistemin çok sayıda farklı ancak geçerli açıklama veya kanıt yolu üretmesine olanak tanır.

Bu teorik zeminin en güncel uygulamalarından biri olan GraphFlow, büyük dil modellerinin (LLM) bilgi çizgelerinden yapılandırılmış veri çekme sürecini GFlowNet mekanizmasıyla yeniden tasarlamaktadır²². Süreç düzeyinde ödül denetimi (process-level supervision) elde etmenin çok pahalı ve zor olduğu karmaşık çizgelerde GraphFlow, bir geri çıkarma politikası ile bir akış tahminleyicisini ortaklaşa eğitir. Nihai sonucun ödülü, aradaki çıkarım adımlarına dağıtılarak "bedava" denetim sinyalleri oluşturulur²³. Bellek sorunlarını ve üstel karmaşıklığı aşmak için "detaylı denge" (detailed balance) adı verilen bir akış eşleştirme fonksiyonu kullanılır. Sistem,

tüm çizgeyi taramak yerine örneklenen yörüngelerdeki düğümlerin komşuluklarına odaklanarak yerel bir keşif (local exploration) stratejisi izler²³. STaRK (Text-Rich Knowledge Graphs) kıyaslamalarında GraphFlow, geleneksel süreç ödül modellerini ve GPT-4o ile desteklenmiş RAG hatlarını, hem doğruluk hem de ulaşılan bilginin çeşitliliği açısından net biçimde geride bırakmaktadır²².

Uçtan Uca Türevlenebilir Nöro-Sembolik Çıkarım Çerçevesi

Nöro-sembolik yapay zekanın uzun yıllardır karşılaştığı en temel problemlerden biri, sinir ağlarının sürekli (continuous) ve türevlenebilir tensör uzaylarında çalışırken, sembolik mantığın ayrık (discrete) ve türevlenemez bir doğaya sahip olmasıdır. Bu uyumsuzluk, sistemin bir bütün olarak geriye yayılım (backpropagation) ile eğitilmesini engellemiş, genellikle sistemleri birbirinden bağımsız iki parçalı modüller haline getirmiştir²⁴. 2025-2026 araştırmaları, bu katı sınırı ortadan kaldıran, mantığı türevlenebilir bir forma sokan yenilikçi matematiksel yaklaşımlar sunmaktadır.

NeuroSymActive: Değer Güdümlü Aktif Keşif ve Türevlenebilir Mantık

Bilgi çizgesi tabanlı soru cevaplama (KGQA) görevlerinde devrim yaratan NeuroSymActive, sembolik tümevarımsal mantık ile Monte Carlo Ağaç Aramasını (MCTS) türevlenebilir bir düzlemde birleştiren modüller bir çerçevedir²⁵. Büyük dil modellerinin statik istemlere (prompts) dayalı yapısının aksine bu sistem, sorgunun çözüm yollarını dinamik olarak puanlar ve yalnızca en yüksek değere sahip yolları genişletir.

NeuroSymActive'in kalbinde, bulanık eşleştirme (soft-unification) yeteneklerine sahip Türevlenebilir Tümevarımsal Mantık Katmanı (Differentiable Inductive Logic Layer - DILL) yer almaktadır. Sistem, veri üzerinden mantıksal tercihleri öğrenirken bu kural ağırlıklarını sürekli olarak günceller²⁷. Aktif keşif kontrolcüsü, bir nöral yol değerlendiricisinin (neural path evaluator) atadığı değer tahminlerini kullanarak arama ağacını yönlendirir ve gereksiz düğüm genişletmelerini durdurur.

Daha da önemlisi, model kendi belirsizliğini otonom olarak yönetebilmektedir. Sistem, tahmin adımlarındaki dağılımsal belirsizliği (heteroscedastic uncertainty) ölçer ve hesaplanan beklenen bilgi kazancı (Information Gain) belirli bir eşiğin üzerinde belirsizlik taşıyorsa, bir "İnsan Oracle" düğümünü tetikleyerek arama sürecine dışsal kesin bilgi dahil eder²⁷. Ağaç arama sürecinin tamamı Gumbel-Softmax gevşetmeleri kullanılarak uçtan uca türevlenebilir hale getirildiğinden, politika, değer ağı ve sembolik kurallar eşzamanlı olarak eğitilebilmektedir. Çok sekmeli karmaşık çıkarımlar gerektiren WebQSP ve CWQ (ComplexWebQuestions) veri setlerinde, NeuroSymActive modeli 8B parametrelili küçük bir LLM omurgasıyla (LLaMa3-8B) sırasıyla %87.1 ve %62.5 isabet oranına (Hits@1) ulaşırken, ChatGPT tabanlı StructGPT modelinden (WebQSP'de %72.6) belirgin şekilde daha başarılı olmuş ve harcanan token miktarını yaklaşık 73 kat azaltmıştır²⁷.

Mantıksal Sinir Ağları (Logical Neural Networks - LNN)

Türevlenebilir mantık alanındaki bir diğer muazzam atılım, IBM Research tarafından geliştirilen Mantıksal Sinir Ağlarıdır (Logical Neural Networks - LNN). Eski nesil hibrit sistemler, sembolik ifadeleri yalnızca nöral ağlar için bir kayıp fonksiyonu (loss function) cezası olarak kullanırken, LNN mimarisinde sinir ağının her bir düğümü (nöronu) doğrudan bir Birinci Dereceden Mantık (First-Order Logic) operatörünü (VE, VEYA, DEĞİL vb.) temsil eder²⁸.

LNN, standart Boole mantığını sürekli değer alanına taşımakla kalmaz, Fréchet eşitsizliklerine dayanan olasılık sınırları (probability bounds) kurarak sistemin kesin olmayan, belirsiz veya eksik veriyle çalışmasına (açık dünya varsayımı) izin verir²⁹. Mantıksal operatörlerin içine yerleştirilen öğrenilebilir ağırlıklar ve eşikler (thresholds), ağın saf veriden kural seti türetmesini sağlar. Klasik sinir ağları gibi tek yönlü (girdiden çıktıya) çalışmak yerine, LNN'ler çok yönlü (omnidirectional) mantıksal çıkarım yapabilir; yani bir hedeften geriye doğru koşulları veya mevcut gerçeklerden ileriye doğru yeni hipotezleri türetebilirler²⁹.

LNN'lerin endüstriyel boyuttaki başarısı tıbbi teşhis ve tahmine yönelik araştırmalarda net bir biçimde görülmektedir. Diyabet teşhisini temel alan çoklu-yol (multi-pathway) LNN modeli, %80.52 doğruluk ve 0.845 AUROC skoru ile Rastgele Orman (Random Forest) ve Destek Vektör Makineleri (SVM) gibi geleneksel modelleri geride bırakmıştır³¹. Sadece yüksek doğruluk sağlamakla kalmayan model, doktorların her bir tıbbi özelliğin tanıdaki ağırlığını doğrudan mantıksal bir eşik olarak okuyabilmesine (tam şeffaflık) olanak tanıyarak klinik olarak benimsenme potansiyelini maksimize etmiştir³².

Olasılıksal Mantık, Ölçeklenebilirlik ve Temel Çizge Modelleri (Foundation Models)

Nöro-sembolik sistemlerin karmaşık mantıksal kuralları ve olasılıksal değerlendirmeleri bir arada kullanması, hesaplama karmaşıklığı açısından tarihi bir bariyer oluşturmuştur. Ayrıca, büyük dil modellerinin dilde elde ettiği "her metne uygulanabilirlik" başarısının, bilgi çizgelerinde sağlanamaması (çünkü her çizgenin farklı varlıkları ve ilişki isimleri vardır), modellerin farklı veri kümelerine transfer edilebilmesini imkansız kılıyordu. 2025-2026 dönemi, hem ölçeklenebilirlik (DeepProofLog) hem de transfer edilebilirlik (ULTRA) açısından bu bariyerleri yıkan gelişmelere sahne olmuştur.

DeepProofLog (DPrL): Olasılıklı Dünyalardan Markov Karar Süreçlerine

Luc De Raedt ve ekibi (KU Leuven) tarafından geliştirilen ve alanda çığır açan DeepProbLog mimarisi, nöral olasılıksal mantık programlamasının temellerini atmış olsa da, kullandığı "olası dünyalar semantiği" (possible world semantics) nedeniyle ciddi bir ölçeklenebilirlik krizi yaşıyordu³⁴. Karmaşık bir çıkarım zincirindeki tüm olası senaryoların değerlendirilmesi, devasa kurumsal çizgelerde sistemin kilitlenmesine neden oluyordu³⁴.

2026 yılında AAAI konferansında sunulan DeepProofLog (DPrL), odağını olası dünyalardan çıkararak "Stokastik Mantık Programları" (Stochastic Logic Programs - SLPs) üzerine odaklanmıştır³⁶. Bu yaklaşımda olasılık değerleri, dünyadaki belirsizliği değil, çıkarımı yürüten

ajanın hangi mantıksal kuralı seçeceğine dair inanç dağılımını ifade eder. DPrL'nin en büyük buluşu, derin stokastik mantık programlarının kanıtlama ve türetme süreçlerini formel olarak bir Markov Karar Süreci (MDP) olarak haritalandırmasıdır³⁸. Her bir çözünürlük adımı, amaca yönelik sürekli bir rehberlik sağlayan sinir ağları tarafından parametrelendirilir³⁴. Mantıksal çıkarım işleminin bir MDP olarak modellenmesi, yapay zekanın diğer alanlarında son derece gelişmiş olan dinamik programlama ve takviyeli öğrenme (RL) tekniklerinin, kanıtlama sürecini yönetmesi için kullanılabilmesini sağlamıştır. Bu sayede nöro-sembolik AI, laboratuvar ölçeğinden devasa gerçek dünya bilgi çizgelerine sorunsuz bir şekilde ölçeklenmiştir³⁴.

ULTRA: Bilgi Çizgeleri İçin Sıfır Atışlı (Zero-Shot) Temel Model

Nöro-sembolik modellerin çizge üzerinde çalışabilmesi için düğüm ve kenarların vektör uzayına dönüştürülmesi (gömüleme - embedding) gerekir. Ancak geleneksel modeller bir çizgenin özel sözlüğünü ezberlediğinden, yeni bir çizgeye aktarılamazlardı. ULTRA, bu sorunu çözmek için varlıkların kendisine değil, ilişkilerin birbirleriyle olan temel topolojik etkileşimlerine odaklanan bir "İlişki Çizgesi" (Graph of Relations) yaklaşımı sunar⁴⁰.

Yönlü ve çok ilişkili bir çizgede, iki ilişkinin yan yana gelme şekli (baş-baş, baş-kuyruk, kuyruk-kuyruk) evrensel bir topolojik gerçekliktir ve çizgedeki kelimelerden bağımsızdır⁴². ULTRA, Anlamsal Koşullu Mesaj İletimi (Semantic Conditional Message Passing - SCMP) mekanizmasını kullanarak, herhangi bir özellik veya metin vektörüne ihtiyaç duymadan, ilişkilerin birbirlerine göre göreceli temsillerini öğrenir⁴³. Bu sayede, yalnızca Freebase, WordNet ve Wikidata tabanlı üç veri seti üzerinde ön eğitimden geçirilen tek bir ULTRA modeli, birbirinden tamamen farklı boyutlara ve varlıklara sahip 57 dış bilgi çizgesinde sıfır atışlı (zero-shot) olarak test edilmiş ve spesifik olarak o çizgeler için eğitilmiş temel modelleri %300'e varan farklarla geride bırakmıştır⁴⁰. Bu genelleştirme yeteneği, nöro-sembolik modellerin dinamik olarak değişen kurumsal veritabanlarında yeniden eğitime ihtiyaç duymadan "anında mantık yürütebilmesini" sağlamıştır.

Sürekli Öğrenme (Continual Learning) ve Dinamik Çizge Belleği

Yapay zeka ajanlarının otonom olarak çevrelerinden bilgi toplaması ve kendini geliştirmesi hedeflenirken karşılaşılan en yıkıcı sorunlardan biri "Katastrofik Unutma" (Catastrophic Forgetting) olgusudur. Geleneksel bir sinir ağı yeni bir görev öğrendiğinde, ağırlıkları yeni veriye göre güncellenir ve eski görevlere ait bilgiler, yeni bilgilerin altında kalarak silinir⁹. Nöro-sembolik yapay zeka, 2025-2026 döneminde bu soruna insan beynindeki mekanizmalara benzer çözümler getirmiştir.

NeSyBiCL: Beyin İlhamlı Melez Öğrenme Çerçevesi

NeSyBiCL (Neuro-Symbolic Brain-Inspired Continual Learning) çerçevesi, hızlı ve sezgisel öğrenme yapan bir sinir ağı ile yavaş ve kalıcı mantıksal çıkarım yapan bir sembolik mekanizmayı birbirine entegre eder⁹. Sinir ağı, sensörlerden veya girdi verilerinden gelen özellikleri hızla öğrenirken, sembolik mekanizma bu özellikleri bilgi çizgeleri formunda soyut,

ilişkisel yapılara dönüştürür⁴⁵. Model, her yeni görev için kavramları ve alt-kavramları temsil eden sınıflara özgü bir grafik oluşturur. Bilginin ağırlık tensörlerinden ziyade ilişkisel düğümler ve kurallar bütünü olarak depolanması, eski bilgilerin üzerine yazılmasını engeller. Çıkarım esnasında sistem, yakın tarihli olaylar için nöral ağı kullanırken, eskimiş görevler için korunan sembolik çizgelere güvenir. Karmaşık bilişsel testlerde NeSyBiCL, yalnızca sinir ağına dayanan sürekli öğrenme algoritmalarına kıyasla unutma oranını ortalama %41 oranında azaltarak, melez modellerin adaptasyon ve bilgi koruma üstünlüğünü kanıtlamıştır⁴⁵.

Uzun Formatlı Videolarda Dinamik Grafik Belleği

Dinamik bilgi çizgelerinin sürekli öğrenme prensipleri, görsel analiz görevlerine de sıçramıştır. Saatler süren videoları analiz eden Uzun Formatlı Video Anlayışı (Long-form Video Understanding - LVU) modelleri, basit ardışık çerçeve analizlerinde bağlamı kaybetmektedir. İnsan bilişinden ilham alan Graph-VideoAgent mimarisi, video dizisi boyunca görsel varlıklar (nesneler, insanlar) arasındaki gelişen ve değişen ilişkileri eşleyen ve takip eden dinamik bir çizge belleği (dynamic graph memory) kullanır⁴⁷.

Bu dinamik bellekte düğümler varlıkları (örn: Köpek, Oyuncak, İnsan) temsil ederken, zamanla eklenen, değişen veya silinen kenarlar eylemleri (örn: Oynamak, Almak, Havlamak) ifade eder. Sistem, bir kişinin oyuncağı almasının köpeğin sinirlenmesine yol açtığı gibi nedensel ilişkileri, yalnızca çerçeve yığınlarına bakarak değil, grafiğin topolojik evrimini takip ederek çözer. LLM ajanı, bu yapılandırılmış hafızayı kullanarak videoları analiz ettiğinde, sektör standardı olan EgoSchema ve NExT-QA veri setlerinde hem doğrulukta (sırasıyla +%2.2 ve +%2.0) yeni bir zirve belirlemiş hem de ihtiyaç duyulan çerçeve sayısını dramatik biçimde azaltarak benzersiz bir verimlilik sağlamıştır⁴⁷. Benzer biçimde EvoRAG adlı güncel sistem, metinsel konuşma bağlamındaki yapılandırılmamış evrimi, kendini sürekli güncelleyen bir bilgi çizgesi ile eşleştirerek büyük dil modellerinin tarihsel pasajları daha tutarlı hatırlamasını sağlamaktadır⁴⁹.

Kurumsal Uygulamalar ve Ekosistem Araçları

Nöro-sembolik modellerin teorik doğrulamasından pratik entegrasyonuna geçiş, 2025 ve 2026 yıllarında donanım üreticileri ve büyük yazılım mimarilerinde geniş yankı bulmuştur. Kurumlar, yapay zekanın sadece üretken olmasını değil, aynı zamanda kararlarını açıklayabilmesini ve yasal düzenlemelere (compliance) uygun olmasını beklemektedir.

Enterprise Bilgi Çizgeleri ve AllegroGraph

Kurumsal ortamlardaki bilgi çizgeleri (Enterprise Knowledge Graphs - EKG), iş değişiklikleri, şirket birleşmeleri ve dinamik süreç modifikasyonları nedeniyle hızla evrimleşir⁵⁰. Bir işletme içindeki milyonlarca belgeyi, veri tabanını ve ilişkiyi anlamlandıran nöro-sembolik sistemler; finansal (FinKG), sağlık (HealthKG) ve üretim (MfgKG) alanlarında test edilmiş ve en iyi sinirsel temel çizgelere karşı sırasıyla %23, %18 ve %15 oranında MRR (Ortalama Karşılıklı Sıra) başarısı elde etmiştir⁵⁰.

Ticari arenadaki en güçlü yansıma, Franz Inc. tarafından geliştirilen ve sektörün ilk tam teşekküllü nöro-sembolik platformu olan AllegroGraph (Sürüm 8.5 ve 9.0) ekosistemidir⁴. Salt

makine öğrenimi tabanlı sistemler veri üzerinde örüntü ararken, AllegroGraph veriyi en küçük anlamlı birim olan RDF üçlülere (Subject-Predicate-Object) üzerinden birbirine bağlayarak ve RDFS/OWL (Web Ontoloji Dili) ontolojilerini kullanarak "öğrenmeyi" değil, doğrudan "anlamayı" (semantics) hedefler⁴. Platforma entegre edilen GraphTalker adlı AI ajanı, karmaşık SPARQL sorgularını yazamayan kurumsal kullanıcıların doğal dille devasa çizgeleri sorgulamasına, ajanların hatalardan öğrenerek iteratif şekilde sonucu rafine etmesine olanak tanır⁵¹. AllegroGraph'ın sağladığı üçlü öznitelik (triple-attributes) mekanizması, güvenliği grafiğin tamamında değil, tekil veri elemanları üzerinde granüler olarak sağlayarak yüksek gizlilik gerektiren sağlık ve finans kuruluşlarında (Agentic AI) ajan tabanlı yapay zekanın önünü açmıştır⁵³.

Otonom Bilimsel Laboratuvarlar (SDL) ve PyGraft

Kimya ve malzeme bilimi gibi disiplinler, otonom yapay zeka ajanlarının deney yapabildiği Kendi Kendini Yöneten Laboratuvarlar (Self-Driving Laboratories - SDLs) ile bilimsel keşif döngüsünü devrimsel bir hıza ulaştırmıştır⁵⁵. Bu ajanlar, yapılandırılmamış literatürden veri çekerek, malzemeler, özellikler ve sentez yolları hakkında nedensel grafikleri (causal processing-structure-property graphs) oluştururlar. Örneğin OntoKG ve MOF-Genie gibi projeler, LLM'lerin çıkarsadığı yapı-özellik ilişkilerini dinamik bir Neo4j bilgi çizgesine aktararak, hidrojen depolama kapasitesi gibi özellikleri grafik sinir ağları ile tahmin etmektedir⁵⁶. Bilimsel hipotez üretimi, halüsinasyon kabul edemeyeceğinden, nöro-sembolik ajanlar LLM'leri, vurucu sinir ağları (spiking neural networks) ve sembolik mantık denetleyicileri ile birleştirerek güvenli bir deney alanı yaratırlar⁵⁶.

Ayrıca bu karmaşık ontolojilerin oluşturulması ve modellerin test edilebilmesi için veri yoksunluğu çeken araştırmacılara destek olmak amacıyla PyGraft kütüphanesi hayata geçirilmiştir⁵⁷. Pierre Monnin ve ekibinin öncülük ettiği bu açık kaynaklı kütüphane, makine öğrenimi veya mantıksal çıkarım algoritmalarının test edilebilmesi için, tıpkı gerçek dünya verisine benzeyen, belirli SHACL kısıtlamalarına uyan devasa sentetik bilgi çizgeleri ve ontolojiler üretmektedir⁵⁷. Buna ek olarak, yapılandırılmamış metinlerden sıfırdan ontoloji türetme işlemi, LLMs4OL (Büyük Dil Modelleri ile Ontoloji Öğrenimi) Challenge gibi uluslararası yarışmalarla hızlandırılmış, RAG (Geri Çıkarma Artırılmış Üretim) ve etki alanına özel LLM'lerin birleşik gücünün geleneksel yöntemleri aştığı kanıtlanmıştır⁶¹. Benzer şekilde, Scallop programlama dili gibi nöro-sembolik derleyiciler, veri bilimcilerin karmaşık yapay zeka görevlerini birbirinden ayrı öğrenme (neural) ve mantık (symbolic) modüllerine ayırarak daha temiz, hızlı ve şeffaf çözümler kodlamasını sağlamıştır¹¹.

Uygulama / Platform	Sektör	Sembolik Entegrasyon Tipi	Başarı Çıktısı
Enterprise KGs (FinKG/HealthKG)	Finans / Sağlık	GAT + Sembolik Kural Çıkarımı	%23'e varan MRR artışı, %40 tepki

			süresi iyileşmesi ⁵⁰
AllegroGraph 8.5 / 9.0	Kurumsal Veri Tabanı	RDF, OWL Ontolojileri, GraphTalker	Güvenli "Agentic AI" altyapısı, doğal dilden SPARQL'e otonom çeviri ⁴
Otonom Laboratuvarlar (SDLs)	Malzeme Bilimi	Çizge Sinir Ağları + Nedensel Ontolojiler	Hata payı sıfıra indirilmiş otonom sentez planlaması ⁵⁵
PyGraft	Araştırma Ekosistemi	SHACL Tabanlı Kısıtlamalar	Mahremiyet ihlali olmadan test için milyonlarca sentetik düğüm inşası ⁵⁷
Scallop	Geliştirici Ortamı	Datalog Tabanlı Bildirimsel Mantık	Kural öğreniminde ve planlamada şeffaf algoritmik ayrıştırma ²⁴

Çözölememiş Temel Problemler ve Araştırma Ufku

Sektörel uygulamalardaki hızlı ilerlemeye rağmen, nöro-sembolik yapay zekanın "insan benzeri" (human-like) tam otonomiye ulaşmasının önünde aşılması gereken temel teorik engeller bulunmaktadır.

- Üst-Biliş (Meta-Cognition) Eksikliği:** 2020-2024 yıllarını kapsayan geniş ölçekli bir literatür incelemesi (PRISMA), nöro-sembolik araştırmaların büyük çoğunluğunun öğrenme algoritmalarına, kural çıkarımına ve bilgi temsiline odaklandığını ortaya koymaktadır. Bununla birlikte, "üst-biliş" çalışmaları literatürün yalnızca %5'ini oluşturmaktadır¹. Üst-biliş, sistemin kendi düşünme sürecini fark etmesi, hatalarını kendi kendine değerlendirmesi ve dinamik ortamlarda hangi verinin nöral, hangi verinin sembolik mekanizmayla işleneceğine otonom olarak karar vermesidir⁷. Kendini denetleme ve düzeltme yetisinden yoksun ajanlar, çevresel koşullar hızla değiştiğinde kırılganlık göstermeye mahkumdur.
- Mantıksal Kayma (Logic Drift) ve Dinamik Ontoloji Evrimi:** Bilgi çizgelerine büyük dil modelleri aracılığıyla sürekli yapılandırılmamış yeni bilgiler (streaming data) aktarıldığında, sistemdeki ontolojilerin ve temel kuralların bu yeni gerçekliklerle uyumlu bir şekilde güncellenmesi gerekir. LLM'in her ürettiği yeni kanıtın (claim), mantıksal doğrulayıcılardan asenkron olarak geçmesi (auto-formalization) işlemi hala çok yavaştır ve gerçek zamanlı kurumsal sistemlerin ölçeklenebilirliğini tehdit etmektedir⁶⁶. Yeniden kural inşaa etme sürecinde yaşanan "Ontolojik Sürüklenme" (Ontology Drift) veya

"Mantıksal Kayma", farklı ajanların birbirleriyle tutarsız kurallar yaratmasına neden olabilmektedir.

3. **İnsan Arayüzleri ve Kesin Eşleşme Zorlukları:** Foundation AgenticOS (FAOS) gibi platformlarda gözlemlenen zorluklardan bir diğeri, girdinin nöral modele girdiği safhada veya modelin çıktığı ürettiği son safhada ontolojik sınırların nasıl çekileceğidir. Özellikle Çıktı-Tarafı Uyumlaştırması (Output-Side Coupling) esnasında, LLM'in doğal dil çıktısının kesin ontolojik şemalara sıfır hata ile yerleştirilmesi (validation) işlemi hala yoğun işlem gücü gerektiren ve sistemin genel yanıt hızını kesen bir darboğazdır⁶⁶.

Sonuç

2025-2026 dönemi, yapay zeka tarihinde büyük dil modellerinin yarattığı coşkunun yerini deterministik şeffaflık arayışına bıraktığı bir "akıllaştırma" süreci olarak kayıtlara geçmektedir. Salt veri yığınlarından öğrenen ve ezberlediği istatistiksel yolları tekrarlayan yapılar; CLAUSE, GraphFlow, NeuroSymActive ve DeepProofLog gibi devrimsel mimarilerle akıl yürüten, karar süreçlerini otonom olarak bütçelendiren ve kendi hafıza çizgelerini dinamik olarak inşa eden ajanlara evrilmiştir.

Statik bilgi çizgelerinin hantallığından kurtulan bu yeni nesil sistemler, ULTRA gibi çizgenin topolojisinden öğrenen temel modeller sayesinde daha önce hiç görmedikleri yapısal veritabanlarında anında mantık yürütebilir hale gelmiştir. Endüstriyel alanda AllegroGraph'ın ajan tabanlı (Agentic AI) ekosistemi ve LNN'in tıp alanındaki mutlak şeffaflığı, yüksek riskli sektörlerin nöro-sembolik yapay zekaya olan güvenini pekiştirmiştir. Üst-biliş ve ontolojik sürüklenme gibi çözülememiş sorunların aşılmasıyla birlikte, nöro-sembolik yapay zeka yalnızca "üçüncü dalganın" değil, nihai Yapay Genel Zeka (AGI) hedefine giden en mantıklı, güvenilir ve açıklanabilir patikanın ta kendisi olmaya devam edecektir.

Alıntılanan çalışmalar

1. [2501.05435] Neuro-Symbolic AI in 2024: A Systematic Review - arXiv, <https://arxiv.org/abs/2501.05435>
2. Neuro-Symbolic AI in 2024: A Systematic Review - CEUR-WS.org, <https://ceur-ws.org/Vol-3819/paper3.pdf>
3. Neuro-Symbolic AI - WALT AI, <https://www.thewalt.ai/neuro-symbolic-ai>
4. The Neuro-Symbolic Foundation for the AI-Driven Enterprise - AllegroGraph, [https://allegrograph.com/the-neuro-symbolic-foundation-for-the-ai-driven-enterpris e/](https://allegrograph.com/the-neuro-symbolic-foundation-for-the-ai-driven-enterprise/)
5. Knowledge Graphs as Grounded World Models for Neuro-Symbolic Artificial Intelligence, <https://zenodo.org/records/18880228>
6. Dynamic Knowledge Graphs - Emergent Mind, <https://www.emergentmind.com/topics/dynamic-knowledge-graphs>
7. Neuro-Symbolic AI in 2024: A Systematic Review - arXiv, <https://arxiv.org/html/2501.05435v2>
8. Parmar, M. Safety, Security, and Cognitive Risks in Neuro-Symbolic AI. arXiv preprint, 2026., <https://arxiv.org/html/2606.17223v1>

9. Hybrid Learners Do Not Forget: A Brain-Inspired Neuro-Symbolic Approach to Continual Learning - arXiv, <https://arxiv.org/html/2503.12635v1>
10. What Is Neuro-Symbolic AI? Complete 2026 Guide - Articsledge, <https://www.articsledge.com/post/neuro-symbolic-ai>
11. Neuro-Symbolic Frameworks: Conceptual Characterization and Empirical Comparative Analysis - arXiv, <https://arxiv.org/html/2509.07122v1>
12. [2509.21035] CLAUSE: Agentic Neuro-Symbolic Knowledge Graph Reasoning via Dynamic Learnable Context Engineering - arXiv, <https://arxiv.org/abs/2509.21035>
13. CLAUSE: Agentic Neuro-Symbolic Knowledge Graph Reasoning via Dynamic Learnable Context Engineering - arXiv, <https://arxiv.org/pdf/2509.21035?>
14. CLAUSE: Agentic Neuro-Symbolic Knowledge Graph Reasoning via Dynamic Learnable Context Engineering - arXiv, <https://arxiv.org/html/2509.21035v1>
15. CLAUSE: Agentic Neuro-Symbolic Knowledge Graph Reasoning via Dynamic Learnable Context Engineering - arXiv, <https://arxiv.org/html/2509.21035v2>
16. Advanced Context Engineering Techniques: A Technical Deep Dive | by Himanshu Sangshetti | Medium, <https://medium.com/@himanshusangshetty/advanced-context-engineering-techniques-a-technical-deep-dive-b997e74cab92>
17. State-of-the-Art Autonomous Agent Architecture: Design Patterns and Best Practices | by Himanshu Sangshetti | Medium, <https://medium.com/@himanshusangshetty/state-of-the-art-autonomous-agent-architecture-design-patterns-and-best-practices-f456add9f07>
18. CLAUSE: Agentic Neuro-Symbolic Knowledge Graph Reasoning via Dynamic Learnable Context Engineering | Request PDF - ResearchGate, https://www.researchgate.net/publication/395848879_CLAUSE_Agentic_Neuro-Symbolic_Knowledge_Graph_Reasoning_via_Dynamic_Learnable_Context_Engineering
19. Resources - Mila GFlowNet Workshop, <https://www.gflownet.org/resources>
20. PRE-TRAINING AND FINE-TUNING GENERATIVE FLOW NETWORKS - ICLR Proceedings, https://proceedings.iclr.cc/paper_files/paper/2024/file/c403577c9d9b4347c24b310fc27453f4-Paper-Conference.pdf
21. Trajectory Balance: Improved Credit Assignment in GFlowNets - ResearchGate, https://www.researchgate.net/publication/401451811_Trajectory_Balance_Improved_Credit_Assignment_in_GFlowNets
22. Can Knowledge-Graph-based Retrieval Augmented Generation Really Retrieve What You Need? - arXiv, <https://arxiv.org/html/2510.16582v1>
23. Can Knowledge-Graph-based Retrieval Augmented Generation Really Retrieve What You Need? - arXiv, <https://arxiv.org/pdf/2510.16582>
24. Scallop: A Language for Neurosymbolic Programming | Request PDF - ResearchGate, https://www.researchgate.net/publication/371357483_Scallop_A_Language_for_Neurosymbolic_Programming
25. [2602.15353] NeuroSymActive: Differentiable Neural-Symbolic Reasoning with Active Exploration for Knowledge Graph Question Answering - arXiv,

- <https://arxiv.org/abs/2602.15353>
26. NeuroSymActive: Differentiable Neural-Symbolic Reasoning with Active Exploration for Knowledge Graph Question Answering - arXiv, <https://arxiv.org/html/2602.15353v2>
 27. NeuroSymActive: Differentiable Neural-Symbolic Reasoning with Active Exploration for Knowledge Graph Question Answering - arXiv, <https://arxiv.org/pdf/2602.15353>
 28. Implementing Tensor Logic: Unifying Datalog and Neural Reasoning via Tensor Contraction, <https://arxiv.org/html/2601.17188v1>
 29. IBM Neuro-Symbolic AI Toolkit (NSTK) - GitHub, <https://github.com/IBM/neuro-symbolic-ai>
 30. arXiv:2402.13440v1 [cs.AI] 21 Feb 2024, <https://arxiv.org/pdf/2402.13440>
 31. Logical Neural Networks for Knowledge Base Completion with Embeddings & Rules | Request PDF - ResearchGate, https://www.researchgate.net/publication/372925225_Logical_Neural_Networks_for_Knowledge_Base_Completion_with_Embeddings_Rules
 32. Explainable Diagnosis Prediction through Neuro-Symbolic Integration - PMC - NIH, <https://pmc.ncbi.nlm.nih.gov/articles/PMC12150699/>
 33. Explainable Diagnosis Prediction through Neuro-Symbolic Integration - arXiv, <https://arxiv.org/html/2410.01855v2>
 34. DeepProofLog: Efficient Proving in Deep Stochastic Logic Programs - AAAI Publications, <https://ojs.aaai.org/index.php/AAAI/article/download/39396/43357>
 35. (PDF) DeepProbLog: Neural Probabilistic Logic Programming - ResearchGate, https://www.researchgate.net/publication/334602669_DeepProbLog_Neural_Probabilistic_Logic_Programming
 36. DeepProofLog: Efficient Proving in Deep Stochastic Logic Programs - arXiv, <https://arxiv.org/html/2511.08581v2>
 37. DeepProofLog: Efficient Proving in Deep Stochastic Logic Programs | Proceedings of the AAAI Conference on Artificial Intelligence, <https://ojs.aaai.org/index.php/AAAI/article/view/39396>
 38. DeepProofLog: Efficient Proving in Deep Stochastic Logic Programs - Lirias - KU Leuven, <https://lirias.kuleuven.be/4414650>
 39. [2511.08581] DeepProofLog: Efficient Proving in Deep Stochastic Logic Programs - arXiv, <https://arxiv.org/abs/2511.08581>
 40. DeepGraphLearning/ULTRA: A foundation model for knowledge graph reasoning - GitHub, <https://github.com/DeepGraphLearning/ULTRA>
 41. ICML Poster How Expressive are Knowledge Graph Foundation Models?, <https://icml.cc/virtual/2025/poster/44147>
 42. ULTRA: Foundation Models for Knowledge Graph Reasoning | by Michael Galkin - Medium, <https://medium.com/data-science/ultra-foundation-models-for-knowledge-graph-reasoning-9f8f4a0d7f09>
 43. Towards Graph Foundation Models: Training on Knowledge Graphs Enables Transferability to General Graphs | OpenReview, <https://openreview.net/forum?id=uKSr3KgEqV>

44. TOWARDS FOUNDATION MODELS FOR KNOWLEDGE GRAPH REASONING - ICLR Proceedings,
https://proceedings.iclr.cc/paper_files/paper/2024/file/85dd09d356ca561169b2c03e43cf305e-Paper-Conference.pdf
45. [Literature Review] Hybrid Learners Do Not Forget: A Brain-Inspired Neuro-Symbolic Approach to Continual Learning - Moonlight,
<https://www.themoonlight.io/en/review/hybrid-learners-do-not-forget-a-brain-inspired-neuro-symbolic-approach-to-continual-learning>
46. Approaches of Neuro-Symbolic Integration: Large Language Models and Knowledge Bases,
https://libeldoc.bsuir.by/bitstream/123456789/59701/1/Golovko_%20Approaches.pdf
47. Understanding Long Videos via LLM-Powered Entity Relation Graphs - arXiv,
<https://arxiv.org/html/2501.15953v1>
48. GDP: Graph-Based Dynamic Personalization for Multimodal Large Language Models - CVF Open Access,
https://openaccess.thecvf.com/content/CVPR2026F/papers/Ray_GDP_Graph-Based_Dynamic_Personalization_for_Multimodal_Large_Language_Models_CVPRF_2026_paper.pdf
49. Paper Digest: CIKM 2025 Papers & Highlights,
<https://www.paperdigest.org/2025/11/cikm-2025-papers-highlights/>
50. Neuro-Symbolic Reasoning for Enterprise Knowledge Graphs: A Hybrid Approach for Enhanced Decision-Making and Knowledge Discovery | TechRxiv,
<https://www.techrxiv.org/doi/10.36227/techrxiv.175303720.01590298>
51. Franz introduces AllegroGraph 8.5, strengthens the semantic foundation for agentic AI,
<https://www.kmworld.com/Articles/News/News/Franz-introduces-AllegroGraph-8.5-strengthens-the-semantic-foundation-for-agentic-AI-173932.aspx>
52. AllegroGraph: Home, <https://allegrograph.com/>
53. AllegroGraph Named a 2025 Trend-Setting Product,
https://allegrograph.com/press_room/allegrograph-named-a-2025-trend-setting-product/
54. Readers' Choice Awards 2025 - Franz: Agentic AI with AllegroGraph's Neuro-Symbolic Knowledge Graphs - KMWorld,
<https://www.kmworld.com/Articles/Editorial/Features/Readers-Choice-Awards-2025---Franz-Agentic-AI-with-AllegroGraphs-Neuro-Symbolic-Knowledge-Graphs-172030.aspx>
55. Self-Driving Laboratories for Chemistry and Materials Science - ChemRxiv,
<https://chemrxiv.org/doi/pdf/10.26434/chemrxiv-2024-rj946-v2>
56. (PDF) From Knowledge to Action: Outcomes of the 2025 Large Language Model (LLM) Hackathon for Applications in Materials Science and Chemistry - ResearchGate,
https://www.researchgate.net/publication/404476490_From_Knowledge_to_Action_Outcomes_of_the_2025_Large_Language_Model_LLM_Hackathon_for_Applications_in_Materials_Science_and_Chemistry

57. PyGraft: Configurable Generation of Synthetic Schemas and Knowledge Graphs at Your Fingertips - ResearchGate,
https://www.researchgate.net/publication/380705182_PyGraft_Configurable_Generation_of_Synthetic_Schemas_and_Knowledge_Graphs_at_Your_Fingertips
58. A library for creating synthetic knowledge graphs - Inria,
<https://www.inria.fr/en/library-synthetic-knowledge-graphs-semantic-web>
59. PyGraft general overview. | Download Scientific Diagram - ResearchGate,
https://www.researchgate.net/figure/PyGraft-general-overview_fig1_380705182
60. The Schema Strikes Back: Refining Knowledge Graphs with Neuro-Symbolic AI - PhD Programme in Computer Science and Mathematics,
<https://dottorato.di.uniba.it/userfiles/downloads/Documenti/Seminari/seminari2025/Pierre%20Monnin%20seminar%2027.01.2025.pdf>
61. LLMs4OL 2025: Large Language Models for Ontology Learning - ResearchGate,
https://www.researchgate.net/publication/397403032_LLMs4OL_2025_Large_Language_Models_for_Ontology_Learning
62. LLMs4OL 2024 Datasets: Toward Ontology Learning with Large Language Models - Zenodo, <https://zenodo.org/records/13851373>
63. LLMs4OL 2024 Datasets: Toward Ontology Learning with Large Language Models, <https://www.tib-op.org/ojs/index.php/ocp/article/view/2480>
64. Neurosymbolic Programming in Scallop: Principles and Practice - Emerald Publishing,
<https://www.emerald.com/ftpgl/article/8/2/118/1326575/Neurosymbolic-Programming-in-Scallop-Principles>
65. Neuro-Symbolic AI in 2024: A Systematic Review - arXiv,
<https://arxiv.org/html/2501.05435v1>
66. Ontology-Constrained Neural Reasoning in Enterprise Agentic Systems: A Neurosymbolic Architecture for Domain-Grounded AI Agents - arXiv,
<https://arxiv.org/html/2604.00555v5>
67. Post-Document Science: From Static Narratives to Intelligent Objects - MDPI,
<https://www.mdpi.com/2305-6703/6/2/14>